


Ruta Batch • RAW → TRUSTED → ANALYTICS

AWS S3 • AWS Glue Spark • Glue Data Catalog • Glue Data Quality • Athena • Power BI



-  **TASA DE RESOLUCIÓN**
% de gestiones resueltas de forma efectiva
-  **TIEMPO DE ESPERA**
Tiempo medio hasta ser atendido
-  **SATISFACCIÓN CIUDADANA**
Valoración de la experiencia en la oficina
-  **INCIDENCIAS**
Volumen y tipología de incidencias
-  **RIESGO OPERATIVO**
Indicadores para la gestión y prevención

MEMORIA TÉCNICA FINAL

Proyecto Piloto Big Data en AWS para el análisis operativo de Oficinas de Empleo

Aplicabilidad institucional: contexto SEPE / Ministerio de Trabajo y Economía Social | Ruta B - Batch

Alumna	FRANCISCA SELMA CATALÁ
Módulo	Big Data
Fecha de entrega	10 de junio
Entregable principal	PDF

Evidencia técnica	Proyecto ejecutado y documentado en AWS Academy / Learner Lab mediante capturas, consultas, scripts y resultados
Carpeta local del proyecto	proyecto_final/ofii/
Enfoque de presentación	Piloto académico de analítica Big Data aplicado a un caso de administración pública: oficinas de empleo, seguimiento operativo y apoyo a la toma de decisiones.

Control del documento

Campo	Contenido
Proyecto	Proyecto Piloto Big Data en AWS - Analítica operativa para oficinas de empleo
Ruta seleccionada	Ruta B - Batch
Servicios principales	Amazon S3, AWS Glue Data Catalog, AWS Glue Data Quality, AWS Glue Spark, Amazon Athena y Power BI
Versión	Memoria técnica final con enfoque profesional de piloto académico aplicable a administración pública
Criterio de entrega	Documento final entregado en la plataforma de la especialización, acompañado de evidencias técnicas del laboratorio en AWS Academy
Alcance institucional	El caso se inspira en necesidades habituales de organismos públicos de empleo, como seguimiento de carga operativa, calidad del dato, reporting territorial y visualización ejecutiva. No representa una implantación oficial del SEPE ni del Ministerio de Trabajo, y no utiliza datos reales de ciudadanos
Naturaleza del dataset	Dataset sintético y académico, diseñado para demostrar un flujo Big Data completo con errores controlados, validación de calidad, transformación batch y explotación analítica

Índice

1. Resumen ejecutivo
2. Contexto, problema y objetivos
 - 2.1 Aplicabilidad institucional: SEPE y administración pública
 - 2.2. Usuarios beneficiarios
3. Requisitos del reto y grado de cumplimiento
 - 3.1 Matriz de afirmaciones fuertes y evidencias obligatorias
4. Caso de uso y dataset
5. Elección de ruta Batch
6. Arquitectura Big Data propuesta
7. Estructura del proyecto consolidado
8. Implementación guiada en AWS Academy
9. Amazon S3: almacenamiento y zonas del Data Lake
10. AWS Glue Data Catalog: metadatos y crawlers
11. AWS Glue Data Quality sobre RAW
12. AWS Glue Spark: transformación y capa TRUSTED
13. Salidas ANALYTICS y KPIs generados
14. AWS Glue Data Quality final
15. Amazon Athena: validación y explotación SQL
16. Power BI: modelo, dashboard e insights
 - ☐ 16.1 Modelo de datos utilizado en Power BI
 - ☐ 16.2 Medidas DAX y KPIs principales
 - ☐ 16.3 Interpretación ejecutiva de los resultados
 - ☐ 16.4 Conclusiones obtenidas a partir del dashboard
17. Resultados e interpretación de negocio
18. Seguridad, gobernanza, coste y rendimiento
19. Riesgos, limitaciones y mitigaciones
20. Conclusiones y mejoras futuras
 - 20.1 Evolución del piloto hacia una solución institucional
21. Uso responsable de IA generativa
22. Anexos técnicos
 - 22.0 Referencia institucional y alcance del caso
 - 22.1 DQDL principal RAW
 - 22.2 DQDL principal TRUSTED

22.3 SQL representativo de Athena

22.4 Medidas DAX representativas

22.5 Extracto de PySpark

23. Checklist final de entrega

1. Resumen ejecutivo

Este proyecto diseña e implementa una arquitectura Big Data batch en AWS para analizar la actividad operativa mensual de una red de oficinas de empleo durante el ejercicio 2025. El trabajo se plantea como un piloto académico aplicable a un contexto de administración pública, tomando como referencia funcional el ámbito de los servicios públicos de empleo y su relación con organismos como el SEPE y el Ministerio de Trabajo y Economía Social.

El objetivo no es simular una implantación oficial ni trabajar con datos reales de ciudadanos, sino demostrar cómo una arquitectura cloud puede transformar datos operativos dispersos en información fiable, trazable y útil para la toma de decisiones. El caso de uso se centra en indicadores como carga de expedientes, resolución mensual, incidencias abiertas, tiempos de espera, satisfacción ciudadana y riesgo operativo por oficina, provincia y periodo.

La solución sigue un patrón de lago de datos por capas. La zona RAW conserva el dato bruto original, incluyendo errores controlados que permiten justificar la fase de calidad. La zona TRUSTED publica datos limpios, normalizados y enriquecidos. La zona ANALYTICS genera salidas preparadas para consulta, validación y visualización ejecutiva.

El proyecto cubre el ciclo completo del dato: ingesta en Amazon S3, catalogación mediante AWS Glue Data Catalog, validación con AWS Glue Data Quality, transformación batch con AWS Glue Spark, explotación SQL mediante Amazon Athena y visualización final en Power BI. Esta secuencia permite demostrar no solo el uso de servicios cloud, sino la conexión lógica entre almacenamiento, calidad, procesamiento, consulta y análisis de negocio.

El valor principal del proyecto está en convertir datos operativos en indicadores accionables. A partir del pipeline desarrollado, es posible identificar oficinas con mayor carga de trabajo, provincias con más presión operativa, periodos con menor capacidad de resolución, incidencias relevantes y niveles de riesgo que requieren seguimiento. De este modo, la arquitectura no se limita a procesar datos, sino que ayuda a priorizar decisiones de gestión.

Como alcance institucional, el SEPE y el Ministerio de Trabajo se utilizan únicamente como contexto de aplicabilidad. El dataset empleado es sintético y académico, diseñado para reproducir problemas habituales de calidad y explotación de datos en entornos organizativos. Por tanto, el proyecto debe interpretarse como una prueba de concepto técnica y no como una solución oficial ni como un análisis sobre datos reales de ciudadanos.

Dimensión	Resultado esperado
Negocio	Identificación de oficinas con mayor carga, más incidencias, menor satisfacción, tiempos de espera elevados o riesgo operativo significativo.
Técnica	Construcción de un flujo batch reproducible en AWS Academy, conectando almacenamiento, catalogación, calidad, transformación, consulta y visualización.
Calidad del dato	Detección de errores en RAW, aplicación de correcciones en Glue Spark y validación de mejora objetiva en la capa TRUSTED
Gobernanza	Mantenimiento de linaje lógico mediante capas diferenciadas, catálogos, reglas de calidad, scripts, consultas SQL y evidencias documentadas.
Explotación analítica	Generación de salidas ANALYTICS preparadas para Athena y Power BI, con KPIs orientados a eficiencia, carga, incidencias, satisfacción y riesgo..
Visualización	Creación de un cuadro de mando ejecutivo en Power BI con indicadores, filtros, visuales temporales, análisis territorial e insights accionables.
El valor diferencial del proyecto reside en que no se limita a cargar un CSV y generar gráficos. Recorre de extremo a extremo el ciclo de vida del dato: ingesta, almacenamiento, catalogación, validación de calidad, transformación, explotación SQL y consumo analítico. Esta continuidad permite defender el resultado final como una solución Big Data completa, trazable y orientada a la toma de decisiones.	

2. Contexto, problema y objetivos

Las oficinas de empleo generan información operativa de forma continua: expedientes recibidos, expedientes resueltos, incidencias abiertas, documentación pendiente, tiempos de espera, nivel de servicio, satisfacción ciudadana y actividad por oficina, provincia y periodo.

Cuando estos datos se gestionan mediante ficheros aislados, procesos manuales o informes no conectados entre sí, aparecen varios problemas: pérdida de trazabilidad, dificultad para reproducir cálculos, riesgo de errores en los indicadores y falta de confianza en la información utilizada para tomar decisiones. En un entorno de gestión pública, esta situación puede limitar la capacidad para detectar oficinas saturadas, priorizar recursos o justificar actuaciones de mejora.

El proyecto reproduce un escenario académico realista dentro de AWS Academy / Learner Lab. Por este motivo, se han priorizado servicios gestionados, escalables y adecuados para una arquitectura batch de baja complejidad operativa. Amazon S3 actúa como almacenamiento principal, AWS Glue permite catalogar, validar y transformar los datos, Amazon Athena facilita la consulta SQL sobre las salidas almacenadas en S3 y Power BI se utiliza como capa final de visualización ejecutiva.

La elección de Athena frente a alternativas como Redshift responde al alcance del laboratorio y al tipo de explotación requerida. El proyecto trabaja con datos procesados por lotes y almacenados en S3, por lo que Athena permite consultar directamente la capa analítica sin necesidad de desplegar ni mantener un clúster. Del mismo modo, AWS Glue Spark permite ejecutar transformaciones reproducibles sobre los datos, manteniendo la lógica de procesamiento dentro de la arquitectura cloud.

El problema que se aborda no es únicamente técnico. La necesidad principal consiste en convertir datos operativos dispersos en indicadores fiables que permitan comprender mejor el funcionamiento de las oficinas de empleo y apoyar decisiones de gestión.

2.1. Aplicabilidad institucional: SEPE y administración pública

El Servicio Público de Empleo Estatal se utiliza en esta memoria como marco de referencia institucional, ya que el caso de uso reproduce necesidades habituales de organismos públicos: trazabilidad del dato, calidad de la información, reporting territorial, seguimiento de cargas operativas y cuadros de mando para responsables de gestión.

La propuesta no afirma ni pretende representar una solución oficial del SEPE ni del Ministerio de Trabajo y Economía Social. Se presenta como un piloto académico de Big Data aplicado a un contexto de administración pública, utilizando datos sintéticos y un escenario funcional inspirado en necesidades reales de gestión.

Este enfoque permite defender el proyecto no solo desde el punto de vista tecnológico, sino también desde el valor público. Una arquitectura de datos bien diseñada puede ayudar a mejorar la transparencia operativa, detectar oficinas con mayor presión asistencial, analizar diferencias territoriales, priorizar acciones de mejora y facilitar decisiones basadas en indicadores fiables.

Tipo	Objetivo
Objetivo general	Diseñar e implementar un pipeline batch de Big Data en AWS que transforme datos operativos de oficinas de empleo en información analítica fiable, trazable y útil para la toma de decisiones.
Específico 1	Crear una estructura de almacenamiento en Amazon S3 separada por capas funcionales: RAW, TRUSTED y ANALYTICS.
Específico 2	Catalogar los datasets mediante AWS Glue Data Catalog para disponer de metadatos, esquemas y tablas consultables.
Específico 3	Aplicar AWS Glue Data Quality sobre la capa RAW para detectar errores y sobre la capa TRUSTED para validar la mejora del dato procesado.
Específico 4	Procesar los datos mediante AWS Glue Spark, aplicando limpieza, normalización, enriquecimiento, control de integridad y cálculo de KPIs.
Específico 5	Generar salidas analíticas preparadas para consulta, incluyendo indicadores por oficina, provincia y resumen ejecutivo.

Específico 6	Consultar y validar la capa analítica mediante Amazon Athena, contrastando resultados con SQL antes de su consumo visual.
Específico 7	Construir un dashboard en Power BI orientado a usuarios de negocio, con KPIs, filtros, visuales temporales, análisis territorial, riesgo operativo e insights accionables.

2.2. Usuarios beneficiarios

Responsables de gestión	Disponer de una visión ejecutiva sobre carga, resolución, incidencias y calidad del servicio.
Coordinadores territoriales	Comparar provincias y oficinas para detectar desigualdades operativas o zonas con mayor presión.
Equipos técnicos de datos	Contar con un pipeline reproducible, trazable y validado mediante reglas de calidad y consultas SQL.
Analistas de negocio	Explorar KPIs, tendencias mensuales, riesgo operativo y detalle por oficina desde Power BI.
Áreas de mejora del servicio	Identificar puntos críticos relacionados con tiempos de espera, satisfacción e incidencias abiertas.

El resultado esperado es una solución batch completa que conecte almacenamiento, catalogación, calidad, transformación, consulta y visualización, demostrando cómo un dato operativo puede convertirse en información útil para la gestión pública.

3. Requisitos del reto y grado de cumplimiento

Esta memoria no reproduce literalmente la numeración del enunciado del reto, sino que reorganiza sus apartados en una estructura técnica de proyecto. No obstante, todos los requisitos solicitados quedan cubiertos y trazados a lo largo del documento mediante secciones específicas, capturas de pantalla, consultas, scripts y resultados verificables.

La ruta seleccionada es la Ruta B - Batch, ya que el caso de uso trabaja con datos operativos mensuales y requiere un flujo de procesamiento por lotes. Esta elección es coherente con la naturaleza del dataset y con el objetivo del proyecto: transformar datos históricos de oficinas de empleo en información analítica preparada para consulta, validación y visualización.

El diseño cubre los bloques obligatorios del reto: definición del caso de uso, dataset, almacenamiento en S3, catalogación con AWS Glue Data Catalog, validación con AWS Glue Data Quality, procesamiento con Glue Spark, explotación mediante Athena y visualización final en Power BI.

3.1. Matriz de cumplimiento del reto

Requisito del reto	Implementación en el proyecto	Evidencia documentada	Estado
Caso de uso realista	Análisis operativo mensual de oficinas de empleo durante 2025	Descripción funcional del caso, objetivos, usuarios beneficiarios e indicadores de negocio	Cumple
Elección de ruta	Ruta B - Batch	Justificación basada en cargas mensuales, procesamiento planificado y reporting operativo	Cumple
Dataset asociado al caso	Dataset sintético de oficinas de empleo con errores controlados	Descripción de columnas, volumen, problemas de calidad y finalidad analítica	Cumple
Almacenamiento en S3	Data Lake organizado en zonas raw/, trusted/, analytics/, scripts/, dq-results/ y athena-results/	Capturas del bucket y estructura de carpetas	Cumple
Glue Data Catalog	Base de datos y crawlers para registrar datasets RAW, dimensiones, TRUSTED y ANALYTICS	Capturas de database, crawlers ejecutados y esquemas catalogados	Cumple

Requisito del reto	Implementación en el proyecto	Evidencia documentada	Estado
Glue Data Quality	Ruleset sobre RAW con detección de errores y ruleset final sobre TRUSTED	Capturas de reglas, ejecuciones, métricas, fallos detectados y validación final	Cumple
Procesamiento Spark / Glue Studio	Glue Spark Job en PySpark implementado desde AWS Glue Studio Script Editor para limpieza, normalización, enriquecimiento y cálculo de KPIs.	Capturas del job, script, parámetros, ejecución correcta y salidas generadas	Cumple
Consulta con Athena	Consultas SQL sobre tablas catalogadas en S3	Capturas de consultas, resultados, validación de filas y KPIs	Cumple
Visualización final en Power BI	Dashboard ejecutivo con KPIs, filtros, gráficos temporales, análisis territorial, riesgo operativo e insights	Capturas del modelo, medidas DAX, dashboard, segmentadores y visuales finales	Cumple
Documentación con evidencias	Memoria técnica con capturas, explicaciones, decisiones técnicas y conclusiones	Documento final estructurado por fases del ciclo de vida del dato	Cumple

3.2. Matriz de afirmaciones técnicas y evidencias

Para evitar que la memoria sea únicamente descriptiva, cada afirmación técnica relevante se acompaña de una evidencia verificable. Esta matriz permite comprobar que las decisiones del proyecto no se presentan de forma aislada, sino respaldadas por capturas, resultados de ejecución, consultas o salidas generadas durante el laboratorio.

Afirmación técnica	Evidencia que la respalda	Valor que aporta
El proyecto utiliza un Data Lake por capas en S3	Captura del bucket con las zonas raw/, trusted/, analytics/, scripts/, dq-results/ y athena-results/	Demuestra separación entre dato bruto, dato depurado, salidas analíticas y evidencias técnicas
Glue Data Catalog registra los datasets del proyecto	Capturas de la base de datos, crawlers ejecutados y esquemas de tablas	Permite consultar los datos desde Athena y aplicar reglas de calidad sobre tablas catalogadas

Afirmación técnica	Evidencia que la respalda	Valor que aporta
Glue Data Quality detecta errores en RAW	Captura del ruleset RAW y resultado con reglas fallidas	Justifica la necesidad de una fase de limpieza antes de explotar los datos
Glue Spark transforma y genera una capa confiable	Captura del Glue Job, script, parámetros y ejecución con estado correcto	Demuestra que el procesamiento batch se ejecuta en AWS y no de forma manual
La capa TRUSTED contiene datos depurados	Capturas de la salida trusted/ en S3 y validaciones posteriores	Evidencia la mejora del dato respecto a RAW
La capa ANALYTICS contiene salidas preparadas para explotación	Capturas de analytics/kpis_oficina, analytics/kpis_provincia y analytics/resumen	Demuestra que el proyecto genera datos listos para consulta y visualización
Athena valida la capa final mediante SQL	Capturas de consultas sobre tablas TRUSTED y ANALYTICS	Aporta una comprobación independiente de los KPIs antes de Power BI
Power BI convierte los datos en información de negocio	Capturas del modelo, medidas DAX, dashboard, filtros, visuales e insights	Cierra el ciclo del dato con una capa de análisis orientada a la toma de decisiones

3.3. Lectura global del cumplimiento

El proyecto cumple los requisitos del reto porque no utiliza los servicios de AWS como elementos aislados, sino como partes conectadas de un flujo completo. Los datos entran en S3, se catalogan con Glue Data Catalog, se validan con Glue Data Quality, se transforman mediante Glue Spark, se consultan con Athena y se visualizan finalmente en Power BI.

Esta trazabilidad permite defender el proyecto desde dos perspectivas. Desde la perspectiva técnica, demuestra una arquitectura batch reproducible y documentada. Desde la perspectiva de negocio, convierte datos operativos de oficinas de empleo en indicadores útiles para analizar carga, eficiencia, incidencias, satisfacción, riesgo operativo y diferencias territoriales.

4. Caso de uso y dataset

El caso de uso analiza el funcionamiento mensual de ocho oficinas de empleo distribuidas en cuatro provincias durante el ejercicio 2025. Cada registro representa la actividad de una oficina en un mes concreto, lo que permite estudiar la evolución operativa del servicio a lo largo del año.

El objetivo del análisis es transformar datos operativos en indicadores útiles para la gestión. A partir del dataset se calculan métricas relacionadas con carga de trabajo, capacidad de resolución, incidencias abiertas, documentación pendiente, tiempos de espera, satisfacción ciudadana, nivel de servicio y riesgo operativo.

El dataset se ha diseñado con una estructura adecuada para una arquitectura batch, ya que los datos se generan y analizan por periodos mensuales. Este enfoque permite comparar oficinas, provincias y meses, detectar desviaciones y construir un cuadro de mando orientado a la toma de decisiones.

4.1. Estructura de los ficheros utilizados

Archivo	Filas	Columnas	Función dentro del proyecto
oficinas_empleo_operativo_raw_2025.csv	97	16	Dataset bruto inicial. Contiene registros operativos mensuales y errores controlados para justificar la fase de calidad y limpieza.
dim_oficinas_empleo.csv	8	8	Dimensión territorial y organizativa de las oficinas. Permite enriquecer el dato operativo con provincia, comunidad, zona u otros atributos de gestión.
dim_calendario_2025.csv	12	6	Dimensión temporal mensual. Permite ordenar, filtrar y analizar la actividad por periodo.
oficinas_empleo_trusted_2025.csv	96	19	Salida limpia, normalizada y enriquecida tras el procesamiento con Glue Spark.
kpis_mensuales_por_oficina_2025.csv	96	14	Capa analítica a grano oficina-mes, utilizada como base principal para KPIs y visualización en Power BI.

Archivo	Filas	Columnas	Función dentro del proyecto
kpis_mensuales_por_provincia_2025.csv	48	11	Capa analítica a grano provincia-mes, orientada a comparación territorial y análisis agregado.
resumen_ejecutivo_2025.csv	1	10	Resumen anual consolidado, utilizado para validar indicadores globales y alimentar la lectura ejecutiva del proyecto.

La relación entre las filas también es relevante para comprender el procesamiento. El dataset RAW contiene 97 registros iniciales, mientras que la capa TRUSTED contiene 96 registros válidos. Esta diferencia se interpreta como resultado del proceso de depuración: el pipeline elimina o excluye registros que no cumplen las condiciones mínimas de integridad necesarias para formar parte del análisis final.

El volumen final de 96 registros es coherente con el grano esperado del análisis: ocho oficinas multiplicadas por doce meses. A partir de esa base se generan las salidas analíticas por oficina, provincia y resumen anual.

4.2. Problemas de calidad incorporados en el RAW

El dataset RAW incluye errores controlados para demostrar la necesidad de una fase de calidad de datos y transformación. Estos problemas permiten justificar el uso de AWS Glue Data Quality y Glue Spark dentro de la arquitectura.

Problema en RAW	Impacto potencial en el análisis	Tratamiento aplicado
Registros incompletos o no válidos	Pueden impedir la segmentación correcta por oficina, provincia o mes.	Exclusión de registros que no cumplen condiciones mínimas de integridad y enriquecimiento mediante dimensiones cuando procede.
Nulos en campos clave	Dificultan la trazabilidad y pueden generar resultados incompletos en agrupaciones territoriales o temporales.	Validación con reglas de completitud y corrección mediante cruce con dimensiones cuando es posible.
Valores negativos en métricas operativas	Generan indicadores imposibles desde el punto de vista de negocio.	Normalización mediante reglas condicionales en Spark para asegurar valores válidos.

Problema en RAW	Impacto potencial en el análisis	Tratamiento aplicado
Satisfacción fuera de rango	Rompe la escala definida de satisfacción ciudadana.	Ajuste al rango permitido entre 1 y 5.
Categorías no controladas en nivel de servicio	Provocan agrupaciones inconsistentes y dificultan el análisis por categoría.	Normalización de valores hacia categorías válidas.
Posibles incoherencias entre expedientes recibidos y resueltos	Pueden producir tasas de resolución no interpretables o superiores al comportamiento esperado.	Control de consistencia durante el procesamiento y validación posterior mediante Athena.
Tiempos de espera nulos o inconsistentes	Afectan a la medición de calidad del servicio.	Imputación controlada o sustitución basada en criterios definidos durante la transformación.

Es importante destacar que no todos los controles de calidad tienen por qué finalizar en descarte de registros. Algunos errores se corrigen mediante normalización, otros se completan mediante enriquecimiento con dimensiones y aquellos que comprometen la integridad mínima del análisis se excluyen de la capa final.

4.3. Valor analítico del dataset

El dataset permite responder preguntas relevantes para la gestión operativa de oficinas de empleo:

Pregunta de análisis	Indicadores utilizados
¿Qué oficinas tienen mayor carga de trabajo?	Expedientes recibidos, expedientes resueltos y documentación pendiente.
¿Qué provincias concentran más presión operativa?	KPIs agregados por provincia y mes.
¿Dónde aparecen más incidencias abiertas?	Incidencias abiertas y ratio de incidencias.
¿Qué oficinas presentan menor calidad de servicio?	Espera media, satisfacción media y nivel de servicio.
¿Qué meses u oficinas requieren seguimiento prioritario?	Riesgo operativo, tasa de resolución e incidencias.
¿El sistema mantiene capacidad de resolución durante el año?	Comparación mensual entre expedientes recibidos y resueltos.

De este modo, el dataset no se limita a almacenar registros operativos, sino que permite construir una lectura completa del servicio: volumen, eficiencia, calidad, territorio y riesgo.

5. Elección de ruta Batch

La ruta elegida para el proyecto es Ruta B - Batch, ya que el caso de uso trabaja con datos históricos y mensuales. El valor del proyecto no depende de procesar eventos en tiempo real, sino de consolidar información fiable, corregida y comparable por oficina, provincia y periodo.

La ruta Batch es adecuada porque permite ejecutar un ciclo completo de ingesta, validación, transformación, consulta y visualización sobre datos acumulados. Este enfoque encaja con un escenario de reporting operativo, donde las decisiones se toman a partir de indicadores consolidados y no de eventos individuales recibidos segundo a segundo.

5.1. Justificación de las decisiones tecnológicas

Decisión	Justificación
Batch en lugar de Streaming	Los datos se analizan por meses y no requieren latencia de tiempo real. El objetivo es consolidar información fiable para reporting operativo.
Amazon S3 como almacenamiento principal	Permite organizar el Data Lake en capas, conservar el dato bruto y almacenar salidas procesadas de forma ordenada.
AWS Glue Data Catalog	Registra los metadatos de los datasets y permite que servicios como Athena y Glue Data Quality trabajen sobre tablas reconocibles.
AWS Glue Data Quality	Permite validar reglas de completitud, unicidad, validez, consistencia y volumetría sobre los datos.
AWS Glue Spark	Permite ejecutar transformaciones reproducibles, aplicar reglas de limpieza, enriquecer datos con dimensiones y generar KPIs.
Athena en lugar de Redshift	Encaja mejor con el alcance del laboratorio, ya que permite consultar directamente datos almacenados en S3 sin desplegar ni administrar un clúster.
Power BI como capa final	Permite construir un cuadro de mando ejecutivo con KPIs, filtros, análisis temporal, análisis territorial e insights accionables.

La elección de esta ruta permite mantener una arquitectura sencilla, trazable y defendible dentro del entorno AWS Academy / Learner Lab. Además, reproduce un patrón habitual en proyectos de analítica: almacenar datos en un lago de datos, aplicar calidad, transformar con Spark, consultar con SQL y visualizar resultados en una herramienta de negocio.

5.2. Resultado esperado de la ruta Batch

El resultado final de la ruta Batch es una capa analítica preparada para explotación. Esta capa permite consultar los datos desde Athena, validar los KPIs principales y construir un dashboard en Power BI orientado a la toma de decisiones.

El flujo queda resumido de la siguiente forma:

Fase	Resultado
Ingesta	Datos RAW y dimensiones cargados en S3.
Catalogación	Tablas registradas en AWS Glue Data Catalog.
Calidad inicial	Errores detectados sobre la capa RAW mediante Glue Data Quality.
Transformación	Datos limpiados, normalizados y enriquecidos mediante Glue Spark.
Capa final	Salidas TRUSTED y ANALYTICS generadas en S3.
Consulta	Validación SQL de resultados mediante Athena.
Visualización	Dashboard final en Power BI con indicadores de negocio.

Esta elección técnica refuerza la coherencia del proyecto, ya que conecta cada servicio con una función concreta dentro del ciclo de vida del dato.

6. Arquitectura Big Data propuesta

La arquitectura del proyecto sigue un patrón de lago de datos organizado por capas. El objetivo de este diseño es separar claramente el dato bruto, el dato depurado y las salidas analíticas preparadas para consulta y visualización.

Amazon S3 actúa como almacenamiento principal del proyecto. Sobre esta base, AWS Glue Data Catalog registra los metadatos de los datasets, AWS Glue Data Quality valida la calidad de los datos, AWS Glue Spark ejecuta las transformaciones batch, Amazon Athena permite consultar las tablas catalogadas mediante SQL y Power BI consume la capa analítica final para construir el cuadro de mando.


El flujo completo puede resumirse de la siguiente manera:

S3 RAW → Glue Data Catalog → Glue Data Quality RAW → Glue Spark → S3 TRUSTED / ANALYTICS → Glue Data Catalog final → Athena → Power BI

Esta arquitectura permite mantener la trazabilidad del dato desde su entrada inicial hasta su consumo final. Cada KPI mostrado en Power BI puede explicarse a partir de una cadena técnica concreta: fichero de origen, validación de calidad, transformación Spark, salida analítica, consulta SQL y visualización.

Figura 1. Arquitectura batch extremo a extremo del proyecto

Proyecto Piloto Big Data en AWS para el análisis operativo de Oficinas de Empleo



La figura muestra la arquitectura completa del proyecto y la función de cada servicio dentro del flujo batch. El dato entra en S3 en estado bruto, se cataloga con Glue Data Catalog, se valida con Glue Data Quality y se transforma mediante Glue Spark. Como resultado, se generan dos capas finales: TRUSTED, con datos limpios y normalizados, y ANALYTICS, con agregados preparados para consulta y visualización.

Athena permite validar los resultados mediante SQL antes de llegar a Power BI. De esta forma, Power BI no actúa como herramienta de limpieza, sino como capa final de análisis y presentación ejecutiva.

Criterio arquitectónico

La separación entre RAW, TRUSTED y ANALYTICS evita mezclar datos brutos con datos depurados o agregados. Esta decisión mejora la trazabilidad, permite repetir transformaciones, facilita la validación de resultados y ayuda a explicar el linaje de cada indicador mostrado en Power BI.

Capa	Servicio principal	Responsabilidad dentro del proyecto
Ingesta batch	Carga controlada en Amazon S3	Incorporar el dataset operativo RAW y las dimensiones auxiliares al entorno de trabajo.
Almacenamiento	Amazon S3	Organizar el Data Lake en zonas funcionales para conservar datos brutos, salidas depuradas, resultados analíticos, scripts y evidencias.
Metadatos	AWS Glue Data Catalog	Registrar tablas, esquemas, ubicaciones y estructura de los datasets para que puedan ser utilizados por Glue, Athena y Data Quality.
Calidad inicial	AWS Glue Data Quality	Detectar errores en la capa RAW antes de realizar transformaciones analíticas.
Procesamiento batch	AWS Glue Spark	Limpiar, normalizar, enriquecer y transformar los datos, generando la capa TRUSTED y las salidas ANALYTICS.
Calidad final	AWS Glue Data Quality	Validar que la capa TRUSTED cumple reglas mínimas de completitud, validez, consistencia y calidad analítica.
Consulta	Amazon Athena	Ejecutar consultas SQL sobre las tablas catalogadas y contrastar los resultados antes de su consumo visual.

Visualización	Power BI	Construir un dashboard ejecutivo y operativo con KPIs, filtros, análisis temporal, análisis territorial e insights accionables.
----------------------	----------	---

Esta arquitectura responde al objetivo principal del reto: construir una solución Big Data completa y coherente, donde los servicios no se utilizan de forma aislada, sino como partes conectadas de un mismo ciclo de vida del dato.

7. Estructura del proyecto consolidado

El proyecto se organiza en una carpeta raíz denominada `ofi/`. Esta estructura local permite mantener separados los datos, scripts, reglas de calidad, consultas SQL, evidencias, documentación y recursos de Power BI.

La organización por carpetas facilita la trazabilidad del trabajo y evita que los ficheros del proyecto queden mezclados. Cada carpeta cumple una función concreta dentro del ciclo de vida del dato.

`ofi/`

- |— `00_powerbi_input_ready/`
- |— `00_s3_upload_ready/`
- |— `01_raw/`
- |— `02_catalogo_glue/`
- |— `02_trusted/`
- |— `03_analytics/`
- |— `04_quality/`
- |— `05_athena/`
- |— `06_spark/`
- |— `07_documentacion_apoyo/`
- |— `08_comandos_opcionales/`
- |— `09_powerbi/`
- |— `10_documentacion_final/`
- |— `11_defensa/`
- |— `00_LEEME_VERSION_CONSOLIDADA.md`
- |— `README_PROYECTO_FINAL.md`

8. Implementación documentada en AWS Academy

La implementación se llevó a cabo en AWS Academy / Learner Lab, utilizando los servicios disponibles en el entorno de laboratorio. Cuando AWS Glue solicitó un rol IAM, se utilizó LabRole, que es el rol habitual proporcionado por el laboratorio para ejecutar servicios gestionados.


El proyecto se documentó mediante capturas de pantalla, resultados de ejecución, consultas SQL y evidencias de las salidas generadas. Este enfoque es importante porque los recursos de AWS Academy pueden depender de la sesión activa del laboratorio, por lo que la memoria debe conservar pruebas claras de cada fase ejecutada.

La implementación siguió una secuencia ordenada, desde la preparación local hasta la visualización final en Power BI.

Fase	Bloque de trabajo	Resultado documentado
0	Preparación local	Organización de la carpeta ofi/ y preparación de datasets, scripts, reglas y consultas.
1	AWS Academy / Learner Lab	Inicio del laboratorio, acceso a la consola y configuración del entorno de trabajo.
2	Amazon S3	Creación del bucket y carga de datasets RAW, dimensiones, scripts y carpetas funcionales.
3	Glue Data Catalog	Creación de la base de datos y ejecución de crawlers iniciales sobre RAW y dimensiones.
4	Glue Data Quality RAW	Ejecución del ruleset inicial y documentación de errores detectados en el dataset bruto.
5	Glue Spark	Ejecución del job PySpark para limpiar, normalizar, enriquecer y generar salidas TRUSTED y ANALYTICS.
6	Catalogación final	Ejecución de crawlers sobre las salidas TRUSTED y ANALYTICS para dejarlas disponibles en Athena.
7	Glue Data Quality final	Validación de la capa TRUSTED para comprobar la mejora objetiva del dato procesado.

8	Amazon Athena	Ejecución de consultas SQL para validar filas, agregados, KPIs e indicadores de negocio.
9	Power BI	Construcción del dashboard final con KPIs, filtros, visuales, tabla de detalle e insights.
10	Entrega	Consolidación de la memoria técnica final con capturas, explicaciones y conclusiones.

Figura 2. Evidencia del entorno AWS Academy / Learner Lab



La captura acredita que el proyecto se desarrolló dentro del entorno AWS Academy / Learner Lab. Esta evidencia contextualiza las decisiones técnicas adoptadas, como el uso de servicios gestionados, LabRole y una arquitectura batch de baja complejidad operativa.

9. Amazon S3: almacenamiento y zonas del Data Lake

Amazon S3 se utiliza como capa principal de almacenamiento del proyecto. Su función es actuar como base del Data Lake, conservando los datos de entrada, las salidas procesadas y las evidencias generadas durante el flujo batch.

La organización del bucket se plantea mediante zonas funcionales. La zona **RAW** conserva los datos originales sin transformar; la zona **TRUSTED** almacena los datos limpios, normalizados y enriquecidos; y la zona **ANALYTICS** contiene las salidas preparadas para consulta en Athena y visualización en Power BI. Además, se reservan espacios para scripts, resultados de calidad y resultados de consultas.

Esta separación permite mantener el linaje del dato durante todo el proyecto. En cualquier momento se puede distinguir qué información corresponde al dato bruto, cuál ha sido procesada y qué ficheros están preparados para explotación analítica.

Una decisión relevante ha sido separar las dimensiones auxiliares en rutas independientes. Esta organización evita que los crawlers de AWS Glue mezclen esquemas distintos durante la inferencia automática y permite catalogar de forma más limpia el dataset operativo, la dimensión de oficinas y la dimensión de calendario.

Desde el punto de vista técnico, S3 no se utiliza simplemente como un repositorio de ficheros, sino como la capa que sostiene el resto de la arquitectura. Sobre sus datos trabajan Glue Data Catalog, Glue Data Quality, Glue Spark, Athena y Power BI.


Evidencias incluidas en esta sección

Evidencia	Qué demuestra
Captura del bucket S3 creado	Acredita la existencia del almacenamiento principal del proyecto.
Captura de las zonas del Data Lake	Muestra la separación entre datos brutos, datos procesados, salidas analíticas y evidencias técnicas.
Captura del dataset RAW cargado	Demuestra que el dato inicial se conserva antes de cualquier transformación.
Captura de las dimensiones auxiliares	Justifica la separación de esquemas para facilitar la catalogación con Glue.
Captura del script Spark en S3	Evidencia que la lógica de transformación queda integrada en el entorno del proyecto.

Interpretación

La estructura de S3 permite explicar el recorrido del dato desde su entrada inicial hasta su consumo final. Primero se conserva el dato bruto, después se genera una capa depurada y finalmente se publican salidas analíticas listas para consulta y visualización. Esta organización mejora la trazabilidad del proyecto y facilita justificar cada KPI mostrado posteriormente en Athena y Power BI.

Figura 3. Creación del bucket principal en Amazon S3




La captura muestra la creación correcta del bucket proyecto-bigdata-oficinas-selma-202506 en Amazon S3, dentro del entorno AWS Academy / Learner Lab.

Esta evidencia marca el punto de partida del Data Lake del proyecto. A partir de este bucket se organizarán las zonas de trabajo necesarias para el flujo batch: datos brutos, datos depurados, salidas analíticas, scripts, resultados de calidad y resultados de consultas.

Desde el punto de vista técnico, la creación del bucket permite disponer de una capa de almacenamiento centralizada sobre la que trabajarán el resto de los servicios de la arquitectura: AWS Glue Data Catalog, AWS Glue Data Quality, AWS Glue Spark, Amazon Athena y Power BI.

Es importante señalar que esta captura acredita la creación del almacenamiento principal, pero no todavía la carga de datos. Las evidencias posteriores documentan la estructura de carpetas, la carga del dataset RAW, las dimensiones auxiliares y las salidas generadas por el procesamiento.

Figura 4. Estructura de zonas del Data Lake en Amazon S3




La captura muestra la organización principal del bucket proyecto-bigdata-oficinas-selma-202506 en Amazon S3. Se observan las zonas funcionales raw/, trusted/, analytics/, scripts/, dq-results/ y athena-results/.

Esta estructura permite separar las fases del ciclo de vida del dato. La zona raw/ conserva los datos originales; trusted/ almacena los datos limpios y normalizados; analytics/ contiene las salidas preparadas para consulta y visualización; scripts/ guarda la lógica de procesamiento; dq-results/ centraliza resultados de calidad; y athena-results/ recoge las salidas generadas por las consultas SQL.

Desde el punto de vista arquitectónico, esta separación evita mezclar datos brutos con datos procesados o resultados de explotación. También facilita la trazabilidad del pipeline, ya que cada fase del proyecto tiene una ubicación concreta dentro del Data Lake.

Esta evidencia refuerza que S3 no se ha utilizado únicamente como repositorio de ficheros, sino como base organizada de la arquitectura Big Data sobre la que trabajan Glue Data Catalog, Glue Data Quality, Glue Spark, Athena y Power BI.

Figura 5. Carga del dataset RAW de oficinas en Amazon S3



La captura muestra la carga correcta del fichero `oficinas_empleo_operativo_raw_2025.csv` en la ruta `s3://proyecto-bigdata-oficinas-selma-202506/raw/oficinas/`.

Esta evidencia acredita la ingesta inicial del dataset operativo en la zona RAW del Data Lake. En esta fase, el fichero se conserva sin transformaciones previas, manteniendo el dato original como punto de partida del pipeline batch.

Desde el punto de vista técnico, esta carga es necesaria para que AWS Glue Data Catalog pueda catalogar posteriormente el dataset y para que AWS Glue Data Quality ejecute las reglas iniciales de validación sobre el dato bruto.

La captura también confirma que la subida finalizó correctamente, sin errores, y que el archivo quedó disponible en S3 para las siguientes fases del proyecto: catalogación, validación de calidad, procesamiento Spark y explotación analítica.

Figura 6. Carga y separación de dimensiones auxiliares en Amazon S3

The figure consists of two screenshots from the AWS S3 console. The top screenshot shows the 'Upload' page for a bucket named 'proyecto-bigdata-oficinas-selma-202506'. A green notification bar at the top states 'Se ha realizado la carga correctamente' (Upload completed successfully). Below this, a summary section shows 'Realizado correctamente' (Completed successfully) with 1 file of 453.0 B (100.00%). The 'Archivos y carpetas' (Files and folders) section shows a table with one entry: 'dim_calendario_2025.csv' (text/csv, 453.0 B, Realizado correctamente). The bottom screenshot shows the 'dimensiones/' folder view. It displays two objects: 'dim_calendario/' and 'dim_oficinas/', both of type 'Carpeta' (Folder). The interface includes navigation tabs for 'Objetos' and 'Propiedades', and various action buttons like 'Copiar URI de S3', 'Copiar URL', 'Descargar', 'Abrir', 'Eliminar', 'Acciones', 'Crear carpeta', and 'Cargar'.


Las capturas evidencian la carga de la dimensión temporal `dim_calendario_2025.csv` y la organización de las dimensiones auxiliares dentro de la ruta `raw/dimensiones/`.

En esta zona se mantienen separadas las dos dimensiones utilizadas por el proyecto: `dim_calendario/` y `dim_oficinas/`. Esta separación permite que AWS Glue Data Catalog pueda catalogar cada dimensión de forma independiente, evitando mezclar esquemas distintos durante la inferencia automática.

La dimensión calendario permite ordenar y analizar la actividad por meses durante el ejercicio 2025. La dimensión de oficinas aporta el contexto territorial y organizativo necesario para enriquecer el dataset operativo durante el procesamiento con Glue Spark.

Esta evidencia confirma que el Data Lake no solo almacena el fichero operativo principal, sino también las tablas auxiliares necesarias para construir una capa TRUSTED más completa y generar KPIs por oficina, provincia y periodo.

Figura 7. Carga del script PySpark en Amazon S3



Las capturas muestran la carga correcta del archivo `glue_spark_job_oficinas_empleo.py` en la carpeta `scripts/` del bucket del proyecto, así como su disponibilidad final dentro de Amazon S3.

Esta evidencia es relevante porque demuestra que la lógica de transformación no quedó fuera de la arquitectura, sino integrada en el propio entorno del Data Lake. El script almacenado en S3 contiene el procesamiento principal del proyecto: limpieza de datos, normalización, enriquecimiento con dimensiones y generación de las capas TRUSTED y ANALYTICS.

Desde el punto de vista técnico, disponer del script en S3 facilita su uso desde AWS Glue y mejora la trazabilidad del pipeline, ya que permite identificar de forma clara qué lógica se ejecuta sobre los datos y dónde se encuentra almacenada.

Con ello, el proyecto no solo conserva los datasets de entrada y salida, sino también el componente central de transformación que conecta la capa RAW con las salidas analíticas utilizadas posteriormente en Athena y Power BI.

10. AWS Glue Data Catalog: metadatos y crawlers

AWS Glue Data Catalog se utiliza como repositorio central de metadatos del proyecto. Su función es convertir los ficheros almacenados en Amazon S3 en tablas lógicas consultables, con nombres de columnas, tipos de datos, ubicación y formato reconocibles por otros servicios de AWS.

Esta catalogación es necesaria porque el proyecto no trabaja únicamente con ficheros CSV aislados. A partir de los datos almacenados en S3, Glue Data Catalog permite que AWS Glue Data Quality aplique reglas sobre tablas reconocidas, que AWS Glue Spark pueda leer datasets estructurados y que Amazon Athena ejecute consultas SQL sobre las capas RAW, TRUSTED y ANALYTICS.

El uso de crawlers facilita la inferencia automática de esquemas y reduce el trabajo manual de definición de tablas. Para evitar mezclas de estructura, cada tipo de dato se rastrea desde una ruta S3 específica: dataset operativo, dimensiones, salida depurada y salidas analíticas.

Crawler	Ruta S3	Finalidad de Catalogación
crawler_raw_oficinas	raw/oficinas/	Catalogar el dataset operativo bruto utilizado como punto de partida del proyecto
crawler_dim_oficinas	raw/dimensiones/dim_oficinas/	Catalogar la dimensión territorial y organizativa de oficinas.
crawler_dim_calendario	raw/dimensiones/dim_calendario/	Catalogar la dimensión temporal mensual del ejercicio 2025.
crawler_trusted_oficinas	trusted/oficinas/	Catalogar la salida limpia, normalizada y enriquecida generada por Glue Spark.
crawler_analytics_oficina	analytics/kpis_oficina/	Catalogar los KPIs mensuales por oficina.
crawler_analytics_provincia	analytics/kpis_provincia/	Catalogar los KPIs mensuales agregados por provincia.
crawler_analytics_resumen	analytics/resumen/	Catalogar el resumen ejecutivo anual utilizado para validación y explotación final.


La separación de crawlers por ruta S3 permite mantener esquemas independientes y facilita la trazabilidad del dato. De este modo, el dataset operativo, las dimensiones y las salidas analíticas quedan identificados como tablas diferenciadas dentro del catálogo.

Nota de coherencia del laboratorio

Durante la ejecución en AWS Academy / Learner Lab, los nombres reales de las tablas catalogadas se generaron a partir de los prefijos de S3. Por este motivo, en Athena se trabajó con nombres como oficinas, trusted_oficinas, analytics_kpis_oficina, analytics_kpis_provincia y analytics_resumen.

Los nombres largos con sufijo 2025 se mantienen como nombres canónicos de los ficheros CSV finales y como referencia documental del proyecto. Esta diferencia no afecta a la coherencia técnica del pipeline: los ficheros, las rutas S3, las tablas catalogadas y las consultas Athena quedan conectados por el mismo flujo de datos.

Figura 8. Base de datos creada en AWS Glue Data Catalog




La captura muestra la creación de la base de datos proyecto_bigdata_oficinas dentro de AWS Glue Data Catalog. Esta base de datos actúa como contenedor lógico de las tablas del proyecto. A partir de ella se registran los datasets almacenados en Amazon S3, incluyendo el dataset RAW de oficinas, las dimensiones auxiliares y las salidas generadas posteriormente en las capas TRUSTED y ANALYTICS.

Desde el punto de vista técnico, esta evidencia marca el inicio de la capa de metadatos del proyecto. Gracias a Glue Data Catalog, los ficheros almacenados en S3 dejan de ser únicamente objetos CSV y pasan a estar descritos como tablas consultables, con columnas, tipos de datos y ubicaciones reconocibles por servicios como AWS Glue Data Quality, AWS Glue Spark y Amazon Athena.

Esta catalogación es fundamental para mantener trazabilidad entre el almacenamiento en S3, las reglas de calidad, las transformaciones batch y las consultas SQL utilizadas en la validación final.

Figura 9. Configuración del crawler RAW en AWS Glue Data Catalog



La captura muestra la creación del crawler crawler_raw_oficinas dentro de AWS Glue Data Catalog. Este crawler se configura sobre la ruta S3 correspondiente al dataset operativo RAW de oficinas y se asocia a la base de datos proyecto_bigdata_oficinas.

La evidencia permite comprobar tres elementos técnicos importantes: el crawler tiene como origen una ruta de Amazon S3, utiliza el rol LabRole proporcionado por AWS Academy / Learner Lab y queda vinculado a la base de datos del proyecto dentro de Glue Data Catalog.

La finalidad de este crawler es inferir automáticamente el esquema del dataset bruto, identificando columnas, tipos de datos y ubicación del fichero. Esta catalogación permite que el dataset deje de ser únicamente un archivo CSV almacenado en S3 y pase a estar disponible como tabla lógica para las siguientes fases del pipeline.

Esta configuración prepara el dato RAW para ser utilizado posteriormente por AWS Glue Data Quality, AWS Glue Spark y Amazon Athena.

Figura 10. Ejecución correcta del crawler RAW

The figure consists of two screenshots of the AWS Glue console interface, showing the configuration and execution of a crawler named 'crawler_raw_oficinas'.

Top Screenshot: Crawler Configuration

- URL:** `us-east-1.console.aws.amazon.com/glue/home?region=us-east-1#/v2/data-catalog/crawlers/view/crawler_raw_oficinas`
- Page Header:** AWS Glue > Crawlers > crawler_raw_oficinas
- Left Sidebar:** Navigation menu with options like 'Getting started', 'ETL jobs', 'Data Catalog', 'Data Integration and ETL', and 'Legacy pages'.
- Main Content Area:**
 - Starting crawler:** A blue banner at the top indicates 'Attempting to start run crawler "crawler_raw_oficinas"'. Below it is a progress bar showing 0% completion.
 - Crawler properties:**
 - Name:** crawler_raw_oficinas
 - IAM role:** LabRole
 - Database:** proyecto_bigdata_oficinas
 - State:** READY
 - Description:** -
 - Security configuration:** -
 - Lake Formation configuration:** -
 - Table prefix:** -
 - Maximum table threshold:** -
 - Advanced settings:** A section for configuring advanced crawler settings.
 - Data sources (1):** A table listing data sources scanned by the crawler.
 - Type:** S3
 - Data source:** s3://proyecto-bigdata-oficinas-selma-202506/raw/oficinas
 - Parameters:** Recrawl all

Bottom Screenshot: Crawler Execution

- URL:** `us-east-1.console.aws.amazon.com/glue/home?region=us-east-1#/v2/data-catalog/crawlers/view/crawler_raw_oficinas`
- Page Header:** AWS Glue > Crawlers > crawler_raw_oficinas
- Left Sidebar:** Same as the top screenshot.
- Main Content Area:**
 - Crawler runs (1):** A table showing the execution history of the crawler.
 - Start time (UTC):** June 6, 2026 at 07:48:13
 - End time (UTC):** June 6, 2026 at 07:49:18
 - Current/last duration:** 01 min 04 s
 - Status:** Completed
 - DPU hours:** 0.051
 - Table changes:** 1 table change, 0 partition changes

La captura muestra la ejecución del crawler crawler_raw_oficinas sobre el dataset operativo almacenado en la zona RAW de Amazon S3. El estado Completed confirma que el crawler se ejecutó correctamente y que AWS Glue pudo analizar la fuente de datos asociada.

El resultado muestra un cambio de tabla en el catálogo, lo que indica que el crawler detectó el fichero RAW y generó o actualizó su definición dentro de la base de datos proyecto_bigdata_oficinas.

Esta evidencia es clave porque conecta la capa de almacenamiento con la capa de metadatos. A partir de esta ejecución, el dataset deja de ser únicamente un archivo CSV en S3 y pasa a estar disponible como tabla lógica dentro de AWS Glue Data Catalog.

Esta catalogación permite que las fases posteriores del proyecto puedan trabajar sobre el dataset de forma estructurada: AWS Glue Data Quality puede aplicar reglas de validación, Glue Spark puede utilizar la tabla como entrada del procesamiento y Athena puede consultarla mediante SQL.

Figura 11. Tabla RAW catalogada y esquema inferido en AWS Glue

The screenshot displays the AWS Glue console interface. The top navigation bar shows the AWS Glue logo and the path 'Tables > oficinas'. The left sidebar contains a navigation menu with options like 'Getting started', 'ETL jobs', 'Visual ETL', 'Notebooks', 'Job run monitoring', 'Data Catalog tables', 'Data connections', 'Workflows (orchestration)', 'Zero-ETL integrations', 'Data Catalog', 'Catalogs', 'Databases', 'Tables', 'Stream schema registries', 'Schemas', 'Connections', 'Crawlers', 'Classifiers', 'Catalog settings', 'Data Integration and ETL', and 'Legacy pages'. The main content area is titled 'oficinas' and shows the 'Table overview' tab. It includes a table details section with fields like Name, Database, Description, Last updated, Classification, Location, Connection, and Column statistics. Below this, the 'Schema' tab is active, displaying a table with 16 columns: registro_id, mes, oficina_id, oficina, provincia, comunidad_autonoma, zona_operativa, canal_principal, prioridad_media_expedientes, expedientes_recibidos, expedientes_resueltos, documentacion_pendiente, incidencias_abiertas, tiempo_medio_espera_min, nivel_servicio, and satisfaccion_media. The schema is listed as 'Schema (16)' and includes buttons for 'Edit schema as JSON' and 'Edit schema'.

#	Column name	Data type	Partition key	Comment
1	registro_id	string	-	-
2	mes	string	-	-
3	oficina_id	string	-	-
4	oficina	string	-	-
5	provincia	string	-	-
6	comunidad_autonoma	string	-	-
7	zona_operativa	string	-	-
8	canal_principal	string	-	-
9	prioridad_media_expedientes	string	-	-
10	expedientes_recibidos	double	-	-
11	expedientes_resueltos	bigint	-	-
12	documentacion_pendiente	bigint	-	-
13	incidencias_abiertas	bigint	-	-
14	tiempo_medio_espera_min	double	-	-
15	nivel_servicio	string	-	-
16	satisfaccion_media	double	-	-

La captura muestra la tabla oficinas creada en AWS Glue Data Catalog dentro de la base de datos proyecto_bigdata_oficinas. Esta tabla queda asociada a la ruta raw/oficinas/ de Amazon S3 y se clasifica como fichero CSV.

En la parte inferior se observa el esquema inferido por Glue, compuesto por 16 columnas. Entre ellas se incluyen campos de identificación, periodo, oficina, provincia, canal, expedientes, incidencias, tiempos de espera, nivel de servicio y satisfacción.

Esta evidencia confirma que el crawler RAW no solo se ejecutó correctamente, sino que convirtió el fichero CSV almacenado en S3 en una tabla estructurada y reutilizable por el resto del pipeline. A partir de esta catalogación, el dataset queda preparado para las siguientes fases: validación con AWS Glue Data Quality, procesamiento con Glue Spark y consulta mediante Athena.

11. AWS Glue Data Quality sobre RAW

La validación inicial sobre la capa RAW tiene como objetivo evaluar la calidad del dataset antes de cualquier transformación. Esta fase es especialmente importante porque el fichero bruto contiene errores controlados introducidos de forma intencional para demostrar la necesidad de una etapa de calidad de datos.

En este punto del proyecto no se espera que todas las reglas se superen. Al contrario, los fallos detectados en RAW justifican el procesamiento posterior con Glue Spark y permiten demostrar una mejora objetiva entre la capa inicial y la capa TRUSTED.

AWS Glue Data Quality se utiliza para comprobar dimensiones básicas de calidad: existencia de columnas, completitud de campos clave, unicidad de identificadores, validez de métricas, rangos permitidos, consistencia de categorías y volumetría mínima.

Dimensión de calidad	Validación aplicada	Finalidad
Estructura	Comprobar que existen las columnas necesarias	Asegurar que el dataset contiene los campos mínimos para ser procesado.
Completitud	Validar que campos clave no estén vacíos	Evitar registros incompletos que impidan segmentar por mes, oficina o provincia.
Unicidad	Verificar que registro_id no se repite	Evitar duplicidades que puedan alterar los conteos y agregados.
Validez numérica	Comprobar que las métricas operativas no sean negativas	Evitar valores imposibles desde el punto de vista de negocio.
Rango	Validar que satisfaccion_media esté entre 1 y 5	Mantener la escala definida para la satisfacción ciudadana.
Consistencia categórica	Comprobar valores permitidos en nivel_servicio y canal_principal	Evitar categorías no controladas que dificulten el análisis.

Dimensión de calidad	Validación aplicada	Finalidad
Volumetría	Comprobar que el número de filas sea suficiente	Detectar cargas vacías o incompletas.

Extracto representativo del ruleset RAW

El ruleset aplicado sobre RAW incluye reglas estructurales, reglas de completitud y reglas de validez de negocio. A continuación, se muestra un extracto representativo:

```
Rules = [
  ColumnExists "registro_id",
  ColumnExists "mes",
  ColumnExists "oficina_id",
  ColumnExists "oficina",
  ColumnExists "provincia",
  ColumnExists "expedientes_recibidos",
  ColumnExists "expedientes_resueltos",
  ColumnExists "incidencias_abiertas",
  ColumnExists "tiempo_medio_espera_min",
  ColumnExists "nivel_servicio",
  ColumnExists "satisfaccion_media",

  IsComplete "registro_id",
  IsComplete "mes",
  IsComplete "oficina_id",
  IsComplete "oficina",
  IsComplete "provincia",
  IsComplete "expedientes_recibidos",


  IsUnique "registro_id",

  ColumnValues "expedientes_recibidos" >= 0,
  ColumnValues "expedientes_resueltos" >= 0,
  ColumnValues "documentacion_pendiente" >= 0,
  ColumnValues "incidencias_abiertas" >= 0,
  ColumnValues "tiempo_medio_espera_min" >= 0,

  ColumnValues "satisfaccion_media" between 1 and 5,
  ColumnValues "nivel_servicio" in ["alto", "medio", "bajo"],
  ColumnValues "canal_principal" in ["presencial", "online", "telefono"]
]
```

El ruleset completo se conserva como evidencia técnica del proyecto. En la memoria se incluye este extracto para mostrar la lógica de validación sin sobrecargar la lectura principal del documento.

Figura 12. Ruleset de calidad aplicado sobre la capa RAW




La captura muestra el ruleset dq_raw_oficinas creado en AWS Glue Data Quality sobre la tabla oficinas, previamente catalogada en AWS Glue Data Catalog.

Este conjunto de reglas valida la estructura y calidad inicial del dataset RAW antes de cualquier transformación. Entre las reglas se incluyen comprobaciones de existencia de columnas, completitud de campos clave, unicidad del identificador de registro, valores numéricos no negativos, rangos válidos para la satisfacción ciudadana y categorías permitidas en campos como nivel de servicio o canal principal.

Esta evidencia demuestra que la calidad del dato se ha incorporado como una fase explícita del pipeline y no como una revisión manual posterior. El objetivo es detectar problemas en el dato bruto antes de utilizarlo para generar KPIs, consultas o visualizaciones.

El ruleset RAW prepara el diagnóstico inicial del dataset y justifica las transformaciones posteriores realizadas con Glue Spark para construir la capa TRUSTED.

Figura 13. Resultado de la evaluación de calidad sobre la capa RAW




La captura muestra la ejecución del ruleset `dq_raw_oficinas` sobre la tabla `oficinas` en AWS Glue Data Quality. La evaluación finaliza correctamente desde el punto de vista técnico, pero el resultado funcional es **fallido**, ya que solo **19 de las 28 reglas evaluadas** se superan satisfactoriamente.

Este resultado confirma que el dataset RAW contiene problemas de calidad que deben corregirse antes de ser utilizado en procesos analíticos. Lejos de representar un error del proyecto, este comportamiento es coherente con el diseño del caso, ya que el fichero bruto incorpora errores controlados de forma intencional para justificar la necesidad de una fase de validación y depuración.

La evidencia demuestra que AWS Glue Data Quality ha detectado de forma automática incidencias en el dato bruto, permitiendo identificar que no todas las condiciones de completitud, validez y consistencia se cumplen en la capa inicial. Esta evaluación justifica técnicamente las transformaciones posteriores aplicadas con Glue Spark para construir la capa TRUSTED.

Figura 14. Detalle de métricas y reglas fallidas en la evaluación RAW



La captura muestra el detalle de la evaluación realizada por AWS Glue Data Quality sobre la tabla RAW oficinas. El resultado global obtiene una puntuación de calidad del **68%**, con **19 reglas superadas de un total de 28**, y un estado final **DQ failed**.

Este resultado confirma que la capa RAW no está preparada para consumo analítico directo. La evaluación no se interpreta como un fallo del proyecto, sino como una evidencia controlada de que el dato bruto contiene problemas que deben resolverse antes de generar KPIs, consultas o visualizaciones.

El detalle de reglas permite diferenciar entre controles superados y validaciones fallidas. Las reglas estructurales se cumplen correctamente, pero aparecen incidencias relacionadas con completitud, valores fuera de rango, métricas no válidas y categorías no controladas. Estos resultados justifican el procesamiento posterior con Glue Spark, donde se aplican acciones de limpieza, normalización, enriquecimiento y control de integridad para construir la capa TRUSTED.

Lectura técnica de los principales fallos detectados

Regla evaluada	Resultado observado en RAW	Lectura técnica	Tratamiento posterior
IsUnique "registro_id"	FAILED	Se detecta una duplicidad en el identificador de registro. En concreto, el registro 2025-01_OFI-SEV-001 aparece repetido en la capa RAW, lo que podría alterar conteos y agregaciones si el dataset se utilizara directamente para análisis.	Deduplicación controlada en Glue Spark mediante <code>dropDuplicates(["registro_id"])</code> , generando una capa TRUSTED con 96 registros únicos a partir de los 97 registros iniciales de RAW.
IsComplete "provincia"	FAILED	Existe al menos un registro sin provincia informada, lo que afecta a la segmentación territorial.	Enriquecimiento o corrección mediante la dimensión de oficinas.
IsComplete "expedientes_recibidos"	FAILED	Se detecta pérdida de información en una métrica clave para calcular carga operativa.	Imputación o reconstrucción controlada mediante reglas de negocio.
ColumnValues "satisfaccion_media" between 1 and 5	FAILED	Aparece un valor fuera de la escala válida de satisfacción ciudadana.	Ajuste al rango permitido entre 1 y 5.
ColumnValues "expedientes_resueltos" >= 0	FAILED	Se detecta un valor negativo, imposible desde el punto de vista operativo.	Normalización a valor válido durante el procesamiento Spark.

Regla evaluada	Resultado observado en RAW	Lectura técnica	Tratamiento posterior
ColumnValues "nivel_servicio" in ["alto", "medio", "bajo"]	FAILED	Existe una categoría no controlada que puede generar agrupaciones inconsistentes.	Normalización hacia una categoría válida.

La lectura de estos resultados enlaza directamente la fase de calidad con la fase de transformación. Los fallos detectados en RAW se convierten en acciones concretas dentro del job de Glue Spark, cuyo objetivo es generar una capa TRUSTED limpia, coherente y preparada para análisis.

12. AWS Glue Spark: transformación y generación de capas TRUSTED y ANALYTICS

El procesamiento principal del proyecto se realiza mediante AWS Glue Spark. Esta fase representa el núcleo técnico del pipeline batch, ya que transforma el dato RAW, previamente validado con AWS Glue Data Quality, en una capa TRUSTED limpia y en salidas ANALYTICS preparadas para consulta y visualización.

El script PySpark consume tres entradas principales almacenadas en Amazon S3: el dataset operativo RAW, la dimensión de oficinas y la dimensión de calendario. A partir de estas fuentes, aplica reglas de limpieza, normalización, enriquecimiento y cálculo de indicadores. El resultado final son datos depurados en trusted/ y ficheros analíticos en analytics/, que posteriormente se catalogan con Glue Data Catalog y se validan con Athena.

Esta fase no se plantea como una transformación manual, sino como un proceso reproducible dentro de AWS Glue. De esta forma, las correcciones aplicadas al dato quedan documentadas en código y pueden repetirse de forma controlada si se vuelve a ejecutar el pipeline.

12.1. Uso de AWS Glue Studio Script Editor

Para dar cumplimiento a la ruta Batch, el procesamiento se implementó en AWS Glue Studio utilizando la modalidad **Script Editor**. Esta opción permite ejecutar un job Spark gestionado por AWS Glue, manteniendo la lógica de transformación en PySpark.

Se eligió Script Editor en lugar de un flujo puramente visual porque el proyecto requiere operaciones que resultan más claras y controlables mediante código: joins con dimensiones, imputaciones, normalización de categorías, control de valores fuera de rango, cálculo de KPIs y generación de varias salidas analíticas.

AWS Glue actúa como servicio gestionado de ejecución. El job utiliza el rol LabRole del entorno AWS Academy / Learner Lab y recibe por parámetros las rutas de entrada y salida en S3. Esta parametrización permite separar la lógica del script de las ubicaciones físicas de los ficheros, haciendo el proceso más trazable y fácil de revisar.

Figura 15. Configuración y parametrización del job Spark en AWS Glue


The screenshot displays the AWS Glue console interface for configuring a job. The job name is 'pegamento_trabajo_oficinas_employado'. The configuration is divided into two main sections: 'Propiedades básicas' (Basic Properties) and 'Propiedades avanzadas' (Advanced Properties).

Propiedades básicas:

- Nombre:** pegamento_trabajo_oficinas_employado
- Descripción (opcional):** (Empty text box)
- Rol de IAM:** Rot en el laboratorio (with a 'Crear nuevo rol' button)
- Tipo:** Chispa
- Versión con pegamento:** Glue 5.1 - Compatible con Spark 3.5, Scala 2 y Python 3.
- Idioma:** Python 3
- Tipo de trabajador:** G TX (4vCPU y 16 GB de RAM)
- Escalar automáticamente el número de trabajadores:** (Unchecked checkbox)
- Número de trabajadores solicitado:** 2

Propiedades avanzadas:

- Número de trabajadores solicitado:** 2
- Generar información sobre empleos:** (Checked checkbox)
- Generar eventos de linaje:** (Unchecked checkbox)
- Marcador de trabajo:** Desactivar
- Cola de ejecución de trabajos:** (Unchecked checkbox)
- Ejecución flexible:** (Unchecked checkbox)
- Número de reintentos:** 0
- Tiempo de espera del trabajo (minutos):** 60
- Perfil de uso:** -



Las capturas muestran la configuración del job pegamento_trabajo_oficinas_empleado en AWS Glue. El job se ejecuta con el rol LabRole del entorno AWS Academy / Learner Lab y utiliza Glue Spark como motor de procesamiento distribuido.


La configuración recoge los aspectos principales del entorno de ejecución: versión de Glue, lenguaje Python, tipo de worker y número de workers asignados. Estos parámetros permiten ejecutar el script PySpark dentro de un servicio gestionado, sin necesidad de administrar infraestructura propia.

La última captura muestra los parámetros del job, donde se definen las rutas de entrada y salida en Amazon S3. Entre ellas se incluyen la ruta del dataset RAW, las dimensiones auxiliares, la salida TRUSTED y las salidas ANALYTICS por oficina, provincia y resumen ejecutivo.

Esta parametrización es relevante porque separa la lógica del script de las rutas físicas del almacenamiento. De este modo, el procesamiento puede repetirse de forma controlada y trazable, manteniendo claro qué datos entran, qué transformaciones se aplican y dónde se publican los resultados.

La evidencia confirma que AWS Glue Spark actúa como núcleo del pipeline batch, conectando la capa RAW con las salidas TRUSTED y ANALYTICS utilizadas posteriormente por Athena y Power BI.

Figura 16. Script PySpark del job de transformación en AWS Glue Studio



La captura muestra el script PySpark cargado en el job pegamento_trabajo_oficinas_empleado dentro de AWS Glue Studio. En la pestaña **Guion** se observa la lógica principal del procesamiento batch, diseñada para transformar datos desde la capa RAW hacia las capas TRUSTED y ANALYTICS.

El script define las rutas de entrada y salida mediante parámetros, incluyendo el dataset operativo RAW, las dimensiones auxiliares, la salida TRUSTED y las salidas analíticas por oficina, provincia y resumen. Esta parametrización permite que el mismo código pueda ejecutarse de forma controlada sobre las ubicaciones configuradas en Amazon S3.

Esta evidencia confirma que la transformación no se ha realizado manualmente, sino mediante un proceso PySpark integrado en AWS Glue. El job centraliza las operaciones de lectura, limpieza, normalización, enriquecimiento y generación de KPIs, actuando como núcleo técnico del pipeline batch.

La presencia del script en Glue Studio refuerza la trazabilidad del proyecto, ya que permite identificar qué lógica transforma los datos brutos y cómo se generan las salidas que posteriormente serán consultadas en Athena y consumidas por Power BI.

Figura 17. Parametrización del job Spark con rutas de entrada y salida en S3

The screenshot displays the AWS Glue Studio interface for the job **pegamento_trabajo_oficinas_empleado**. At the top, a green notification bar states: "Successfully updated job. Successfully updated job glue_job_oficinas_empleo. To run the job choose the Run Job button." The interface includes tabs for **Guion**, **Detalles del trabajo**, **Corre**, **Calidad de los datos**, **Horarios**, and **Control de versiones**. The **Guion** tab is selected, showing a table of parameters:

Parameter Name	Value	Action
--RAW_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--DIM_OFICINAS_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--DIM_CALENDARIO_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--TRUSTED_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--ANALYTICS_OFICINA_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--ANALYTICS_PROVINCIA_PATH	s3://proyecto-bigdata-oficinas-	Eliminar
--ANALYTICS_RESUMEN_PATH	s3://proyecto-bigdata-oficinas-	Eliminar

Below the table, there is a button **Agregar nuevo parámetro** and a note: "Puedes añadir 43 parámetros más." The bottom of the interface shows the **CloudShell** tab and footer information: "© 2026, Amazon Web Services, Inc. o sus filiales. Privacidad Términos Preferencias de cookies".


La captura muestra la parametrización del job pegamento_trabajo_oficinas_empleado en AWS Glue. En los parámetros del trabajo se definen las rutas S3 utilizadas por el script PySpark para leer los datos de entrada y escribir las salidas del procesamiento.

Los parámetros incluyen la ruta del dataset RAW, las rutas de las dimensiones auxiliares, la salida TRUSTED y las salidas ANALYTICS por oficina, provincia y resumen ejecutivo. Esta configuración permite que el script no dependa de rutas fijas escritas de forma rígida dentro del código, sino de valores gestionados desde la configuración del job.

Desde el punto de vista técnico, esta parametrización mejora la trazabilidad y la reproducibilidad del pipeline. Permite identificar de forma clara qué datos entran al proceso, qué rutas se utilizan como apoyo y dónde se publican los resultados finales.

La evidencia también confirma que el job fue actualizado correctamente antes de su ejecución, dejando preparada la transformación batch que conecta la capa RAW con las capas TRUSTED y ANALYTICS.

Figura 18. Inicio y finalización correcta del job Spark en AWS Glue



Las capturas muestran dos momentos de la ejecución del job `pegamento_trabajo_oficinas_empleado` en AWS Glue. La primera evidencia el lanzamiento del proceso, con el mensaje “Successfully started job”, confirmando que el job se inició correctamente a partir de la configuración y los parámetros definidos.

La segunda captura muestra el resumen de ejecuciones del job. En ella se observa una ejecución total, una ejecución exitosa, cero ejecuciones fallidas y una tasa de éxito del 100%. Además, el estado de la ejecución aparece como “Tuvo éxito”, lo que confirma que el procesamiento Spark finalizó correctamente dentro del entorno AWS Academy / Learner Lab.

Esta evidencia es clave porque demuestra que la transformación no quedó únicamente definida en el script, sino que fue ejecutada realmente en AWS Glue. El job procesó los datos RAW y las dimensiones auxiliares, aplicó la lógica de limpieza, normalización, enriquecimiento y generación de KPIs, y dejó preparadas las salidas en las capas TRUSTED y ANALYTICS.

Desde el punto de vista del pipeline, estas capturas cierran la fase de procesamiento batch: primero se valida que el job puede iniciarse con la configuración establecida y después se acredita que la ejecución terminó correctamente. A partir de este punto, las salidas generadas pueden ser catalogadas, consultadas en Athena y utilizadas en Power BI.

12.2 y 12.3. Tabla integrada del procesamiento RAW → TRUSTED → ANALYTICS

La siguiente tabla resume las entradas, salidas y principales reglas de transformación aplicadas en el job de Glue Spark. Su objetivo es mostrar, de forma compacta, cómo el dato bruto se convierte en una capa depurada y en salidas analíticas preparadas para Athena y Power BI.

Bloque	Elemento	Recurso o técnica aplicada	Resultado	Valor para el proyecto
Entradas	Dataset RAW	Dataset operativo de oficinas	Contiene la actividad mensual inicial con errores controlados.	Fuente base del procesamiento.
Entradas	Dimensión de oficinas	<code>dim_oficinas_empleo.csv</code>	Aporta información territorial y organizativa.	Permite análisis por provincia, comunidad autónoma y zona operativa.
Entradas	Dimensión de calendario	<code>dim_calendario_2025.csv</code>	Facilita el análisis mensual del ejercicio 2025.	Ordena la lectura temporal de los KPIs.
Salidas	Capa TRUSTED	<code>trusted/oficinas/</code>	Publica datos limpios, normalizados y enriquecidos.	Crea una base fiable para explotación analítica.

Bloque	Elemento	Recurso o técnica aplicada	Resultado	Valor para el proyecto
Salidas	ANALYTICS oficina	analytics/kpis_oficina/	Genera KPIs mensuales por oficina.	Permite seguimiento operativo individual.
Salidas	ANALYTICS provincia	analytics/kpis_provincia/	Genera KPIs mensuales agregados por provincia.	Facilita comparación territorial.
Salidas	ANALYTICS resumen	analytics/resumen/	Genera un resumen anual ejecutivo.	Sintetiza resultados para dirección.
Transformación	Control de integridad	Validación de claves y cruce con dimensiones	Excluye registros sin condiciones mínimas para el análisis final.	Garantiza calidad mínima del dato.
Transformación	Enriquecimiento territorial	Join con dimensión de oficinas	Consolida provincia, comunidad autónoma y zona operativa.	Aporta contexto organizativo.
Transformación	Métricas negativas	Reglas condicionales en Spark	Corrige valores operativamente imposibles.	Evita distorsiones en KPIs.
Transformación	Nulos en expedientes recibidos	Reconstrucción controlada mediante métricas relacionadas	Preserva la medición de carga operativa cuando existe información suficiente.	Mantiene continuidad del análisis.
Transformación	Tiempos de espera nulos	Imputación mediante medias de referencia	Reduce el impacto de valores ausentes.	Refuerza KPIs de calidad del servicio.
Transformación	Satisfacción fuera de rango	Limitación al rango válido entre 1 y 5	Mantiene la escala definida para satisfacción.	Asegura comparabilidad.
Transformación	Nivel de servicio	Homogeneización de categorías	Corrige valores no controlados.	Permite segmentaciones coherentes.
Transformación	KPIs derivados	Cálculo de tasas, ratios y riesgo operativo	Prepara la información para Athena y Power BI.	Convierte datos procesados en información de gestión.

Esta tabla sintetiza el flujo RAW → TRUSTED → ANALYTICS. Las entradas proporcionan el dato inicial y las dimensiones de contexto; las transformaciones corrigen los problemas detectados en RAW; y las salidas publican datasets preparados para validación SQL, análisis territorial y visualización ejecutiva.

12.4. Consolidación de la capa TRUSTED

El dataset RAW inicial contiene 97 registros. Tras el procesamiento con Glue Spark, la capa TRUSTED queda consolidada con 96 registros válidos, coherente con el grano esperado del análisis: ocho oficinas por doce meses.

Esta diferencia responde a la deduplicación controlada del campo registro_id. La evaluación de AWS Glue Data Quality sobre RAW detecta que la regla IsUnique "registro_id" falla debido a un duplicado intencional en el fichero bruto. Durante el procesamiento Spark se aplica dropDuplicates(["registro_id"]), eliminando la repetición y conservando una única versión de cada registro.

Esta decisión mejora la calidad del dato y evita que los KPIs posteriores se vean alterados por registros duplicados. Como resultado, la capa TRUSTED queda preparada para consulta en Athena y consumo en Power BI con 96 registros únicos y sin duplicidades en la clave de análisis.

12.5. Extracto representativo del job PySpark

El script completo se conserva como evidencia técnica en la carpeta 06_spark/ y en la ruta scripts/ del bucket S3. En la memoria se incluye únicamente un extracto representativo para mostrar la lógica general del procesamiento sin sobrecargar el documento principal.

```
args = getResolvedOptions(
    sys.argv,
    [
        "RAW_PATH",
        "DIM_OFICINAS_PATH",
        "DIM_CALENDARIO_PATH",
        "TRUSTED_PATH",
        "ANALYTICS_OFICINA_PATH",
        "ANALYTICS_PROVINCIA_PATH",
        "ANALYTICS_RESUMEN_PATH",
    ],
)

raw_df = spark.read.option("header", True).csv(args["RAW_PATH"])
```

```

dim_oficinas_df = spark.read.option("header", True).csv(args["DIM_OFICINAS_PATH"])
dim_calendario_df = spark.read.option("header", True).csv(args["DIM_CALEDARIO_PATH"])

trusted_df = (
    raw_df
    .join(dim_oficinas_df, on="oficina_id", how="inner")
    .join(dim_calendario_df, on="mes", how="left")
)

trusted_df.write.mode("overwrite").option("header", True).csv(args["TRUSTED_PATH"])

```

Este fragmento resume la filosofía del job: leer entradas desde S3, integrar dimensiones, generar una salida depurada y dejar el resultado disponible para su catalogación y explotación posterior.

12.6. Parametrización del job

El job se parametriza mediante rutas S3 para separar la lógica de transformación de las ubicaciones concretas de entrada y salida. Esta práctica facilita la revisión del proceso y permite reutilizar el script si cambian las rutas del entorno.

Parámetro	Función
RAW_PATH	Ruta del dataset operativo RAW.
DIM_OFICINAS_PATH	Ruta de la dimensión territorial y organizativa de oficinas.
DIM_CALEDARIO_PATH	Ruta de la dimensión temporal mensual.
TRUSTED_PATH	Ruta de salida para la capa TRUSTED.
ANALYTICS_OFICINA_PATH	Ruta de salida para KPIs mensuales por oficina.
ANALYTICS_PROVINCIA_PATH	Ruta de salida para KPIs mensuales por provincia.
ANALYTICS_RESUMEN_PATH	Ruta de salida para el resumen ejecutivo anual.

Las rutas utilizadas deben coincidir con las evidencias del bucket S3 mostradas en la memoria. En caso de que el laboratorio haya generado prefijos específicos, se documentan los nombres reales utilizados durante la ejecución.

12.7. Valor técnico de esta fase

La fase de Glue Spark es la que convierte el diagnóstico de calidad en una capa analítica utilizable. Antes del procesamiento, el dataset RAW contiene errores de completitud, valores fuera de rango y categorías no controladas. Después del procesamiento, se obtiene una capa TRUSTED más coherente y salidas ANALYTICS preparadas para validación SQL y visualización.

Esta fase es clave porque evita que Power BI consuma directamente datos brutos. Los indicadores que llegan al dashboard proceden de un proceso previo de depuración, enriquecimiento y validación, lo que mejora la confianza en los resultados mostrados.

13. Salidas TRUSTED, ANALYTICS y KPIs generados

Tras la ejecución correcta del job de AWS Glue Spark, el pipeline genera dos tipos de salidas principales. La capa TRUSTED contiene el dato limpio, normalizado y enriquecido a grano mensual por oficina. La capa ANALYTICS publica salidas agregadas y orientadas al consumo analítico: KPIs por oficina, KPIs por provincia y resumen ejecutivo anual.


Esta separación permite distinguir entre el dato depurado de base y los datasets ya preparados para consulta, validación SQL y visualización en Power BI.

13.1. Salidas generadas por el pipeline

Salida generada	Ruta S3 / tabla lógica	Filas	Uso principal
oficinas_empleo_trusted_2025.csv	trusted/oficinas/	96	Base limpia, normalizada y validable.
kpis_mensuales_por_oficina_2025.csv	analytics/kpis_oficina/	96	Detalle mensual por oficina para análisis operativo.
kpis_mensuales_por_provincia_2025.csv	analytics/kpis_provincia/	48	Agregado mensual por provincia para comparación territorial.
resumen_ejecutivo_2025.csv	analytics/resumen/	1	KPIs anuales globales para lectura ejecutiva.

El volumen de la capa TRUSTED, con 96 registros, es coherente con el grano esperado del análisis: ocho oficinas por doce meses. Las salidas analíticas mantienen esa lógica y la adaptan a distintos niveles de consumo: oficina, provincia y resumen anual.

Figura 19. Generación de la capa TRUSTED en Amazon S3



La captura acredita la creación de la salida trusted/oficinas/ en Amazon S3 tras la ejecución del job de Glue Spark.

Esta evidencia demuestra que el procesamiento no se limitó a ejecutar código, sino que produjo una salida física en el Data Lake. La capa TRUSTED representa el dato operativo ya depurado, normalizado y enriquecido, preparado para ser catalogado, validado y consultado posteriormente.

Desde el punto de vista técnico, esta salida conecta la fase de transformación con las fases finales del proyecto. A partir de trusted/oficinas/, se puede ejecutar una validación de calidad final, registrar la tabla en Glue Data Catalog, consultar el resultado desde Athena y utilizar los datos como base para KPIs y visualizaciones.

La existencia de esta capa permite diferenciar claramente entre el dato RAW original, que contenía errores controlados, y el dato TRUSTED, que constituye la versión fiable para explotación analítica.

Figura 20. Salidas ANALYTICS generadas en Amazon S3

The screenshot displays the Amazon S3 console interface. The top navigation bar shows the AWS logo, a search bar, and the account ID. The breadcrumb trail indicates the path: Amazon S3 > Buckets > proyecto-bigdata-oficinas-selma-202506 > analytics/.

The main section is titled 'analytics/' and has two tabs: 'Objetos' (selected) and 'Propiedades'. Below the tabs, there are buttons for 'Copiar URI de S3', 'Copiar URL', 'Descargar', 'Abrir', 'Eliminar', 'Acciones', 'Crear carpeta', and 'Cargar'.

The 'Objetos (3)' section shows a list of three folders:

Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento
kpis_oficina/	Carpeta	-	-	-
kpis_provincia/	Carpeta	-	-	-
resumen/	Carpeta	-	-	-

The 'kpis_oficina/' folder is selected, and the view is updated to show its contents. The 'Objetos (1)' section shows a single CSV file:

Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento
part-00000-50c13a2f-7dee-4e25-aedf-9506287dc9dd-c000.csv	csv	6 Jun 2026 10:57:04 AM CEST	10.6 KB	Estándar

The bottom of the screenshot shows the footer with 'CloudShell', 'Comentarios', and copyright information for Amazon Web Services, Inc. © 2026.

La figura muestra que el job de Glue Spark generó la capa ANALYTICS dentro de S3, organizada en tres salidas diferenciadas: KPIs por oficina, KPIs por provincia y resumen ejecutivo. Esta organización prepara los datos para distintos niveles de análisis: operativo, territorial y directivo.

Figura 21. Generación de KPIs provinciales en la capa ANALYTICS


The screenshot displays the AWS S3 console interface. At the top, the navigation bar shows the AWS logo, a search bar, and the account ID. The breadcrumb trail indicates the path: Amazon S3 > Buckets > proyecto-bigdata-oficinas-selma-202506 > analytics/. The 'analytics/' bucket is selected, and the 'Objetos' tab is active. Below the tab, there are buttons for 'Copiar URI de S3', 'Copiar URL', 'Descargar', 'Abrir', 'Eliminar', 'Acciones', 'Crear carpeta', and 'Cargar'. A search bar for objects is present. The table of objects lists three items: 'kpis_oficina/' (Carpeta), 'kpis_provincia/' (Carpeta), and 'resumen/' (Carpeta). The 'kpis_provincia/' object is selected, and its details are shown below the table. The details include the object name 'part-00000-d99659ce-a699-4223-be11-f0d1a457e355-c000.csv', type 'csv', last modified date '6 Jun 2026 10:57:06 AM CEST', size '3.5 KB', and storage class 'Estándar'.

La captura muestra la salida analytics/kpis_provincia/ dentro del bucket del proyecto en Amazon S3. Esta carpeta contiene el fichero CSV generado por el job de Glue Spark con los indicadores mensuales agregados por provincia.

Esta evidencia confirma que la capa ANALYTICS no se limita al detalle operativo por oficina, sino que también incorpora una salida específica para análisis territorial. Esta agregación permite comparar provincias, detectar diferencias de carga operativa y evaluar el comportamiento mensual del servicio desde una perspectiva geográfica.

Desde el punto de vista técnico, la salida kpis_provincia/ prepara los datos para ser catalogados, consultados en Athena y utilizados posteriormente en Power BI. Desde el punto de vista de negocio, permite construir visuales de ranking provincial, comparación territorial y priorización de zonas con mayor presión operativa.

Figura 22. Generación del resumen ejecutivo en la capa ANALYTICS



La captura muestra la salida analytics/resumen/ dentro del bucket del proyecto en Amazon S3. Esta carpeta contiene el fichero CSV generado por el job de Glue Spark con el resumen ejecutivo anual del ejercicio 2025.

Esta evidencia confirma que la capa ANALYTICS incluye una salida de síntesis orientada a consumo directivo. Mientras que kpis_oficina/ permite el análisis operativo detallado y kpis_provincia/ permite la comparación territorial, resumen/ consolida los principales indicadores globales del proyecto.


Desde el punto de vista técnico, esta salida permite validar los KPIs anuales mediante Athena y utilizarlos como referencia para las tarjetas ejecutivas en Power BI. Desde el punto de vista de negocio, facilita una lectura rápida del estado general del servicio: volumen de expedientes, capacidad de resolución, incidencias, documentación pendiente, espera media y satisfacción.

La existencia de esta salida demuestra que el pipeline no solo limpia datos, sino que también produce información agregada preparada para la toma de decisiones.

Las salidas de la capa ANALYTICS permiten consumir la información a distintos niveles de detalle. La salida por oficina conserva el grano operativo mensual, la salida por provincia permite comparar territorios y el resumen ejecutivo consolida los KPIs anuales del proyecto.

Esta organización facilita que Athena y Power BI trabajen sobre datasets ya preparados para explotación, evitando calcular todos los agregados directamente desde el dato RAW. De este modo, la arquitectura mantiene separación entre limpieza, transformación, validación y consumo analítico.

Figura 23. Catalogación final de las capas TRUSTED y ANALYTICS en AWS Glue



La captura muestra la ejecución correcta de los crawlers finales en AWS Glue Data Catalog. Se observan los crawlers asociados a la capa RAW, a la capa TRUSTED y a la capa ANALYTICS, todos con estado de última ejecución **Succeeded**.

Esta evidencia confirma que, después de generar las salidas del job de Glue Spark en Amazon S3, los datos procesados fueron incorporados de nuevo al catálogo de metadatos. En concreto, el crawler de TRUSTED registra la salida trusted/oficinas/, mientras que el crawler de ANALYTICS registra las salidas analíticas generadas para oficina, provincia y resumen ejecutivo.

El resultado del crawler de ANALYTICS muestra la creación de tres tablas, coherente con las tres salidas publicadas en S3: kpis_oficina/, kpis_provincia/ y resumen/. De esta forma, las salidas dejan de ser únicamente ficheros CSV en S3 y pasan a estar disponibles como tablas lógicas para consulta y validación.

Esta catalogación final es necesaria para que Amazon Athena pueda consultar los resultados y para que AWS Glue Data Quality pueda ejecutar una validación final sobre la capa TRUSTED.

13.2. Indicadores ejecutivos generados

Indicador ejecutivo	Valor
Expedientes recibidos total	191.319
Expedientes resueltos total	167.286
Incidencias abiertas total	4.759
Documentación pendiente total	11.512
Tasa de resolución global	87,44%
Espera media global	42,2 min
Satisfacción media global	3,38

Estos indicadores resumen la actividad anual consolidada y sirven como base para las validaciones posteriores en Athena y para la construcción del dashboard en Power BI. Su valor no está únicamente en el cálculo numérico, sino en que proceden de una capa procesada y trazable, generada después de la validación de calidad y la transformación Spark.

14. AWS Glue Data Quality final sobre TRUSTED

Tras ejecutar el job de AWS Glue Spark, se realiza una segunda validación de calidad sobre la capa TRUSTED. Esta evaluación tiene como objetivo comprobar que los datos finales cumplen las condiciones necesarias para ser consultados en Athena y consumidos posteriormente en Power BI.

A diferencia de la validación inicial sobre RAW, donde se esperaba detectar errores, en la capa TRUSTED el resultado esperado es que las reglas principales se superen correctamente. Esta comparación permite demostrar una mejora objetiva entre el dato bruto y el dato procesado.

Durante la revisión del ruleset dq_trusted_oficinas, se ajustó una regla de unicidad inicialmente aplicada sobre tiempo_medio_espera_min. Esta regla se consideró excesivamente restrictiva porque el tiempo medio de espera es una métrica operativa y no un identificador; por tanto, es normal que varias oficinas o meses compartan el mismo valor. La regla se eliminó para mantener un criterio de calidad correcto, centrado en claves, completitud, rangos válidos y consistencia de negocio.

Tras este ajuste, la evaluación de AWS Glue Data Quality sobre la tabla trusted_oficinas finalizó correctamente con un **score del 100%**, superando **62 de 62 reglas**.

Figura 24. Ruleset final de calidad aplicado sobre la capa TRUSTED

The screenshot displays the AWS Glue console interface for a ruleset named 'dq_trusted_oficinas'. The left sidebar shows the navigation menu with options like 'Getting started', 'Data Catalog', 'Data Integration and ETL', and 'Legacy pages'. The main content area shows the 'Ruleset details' for 'dq_trusted_oficinas', including its description, creation date (June 6, 2020 at 10:11:08), last modified date (June 6, 2020 at 10:28:32), and a 'Run' button. Below this, the 'Rules (DQDL)' section lists numerous rules for data quality checks, such as 'Rowcount between 48 and 192', 'Uniqueness "registro_id" > 0.95', 'Columnlength "provincia" between 5 and 18', and 'Uniqueness "expedientes_recibidos" > 0.95'. The rules are organized into a list with their respective column names and conditions.


La captura muestra el ruleset `dq_trusted_oficinas` creado en AWS Glue Data Quality sobre la tabla `trusted_oficinas`. Este conjunto de reglas se aplica después de la ejecución del job de Glue Spark, una vez generada la capa depurada del proyecto.

El ruleset final valida que la capa TRUSTED contiene las columnas necesarias, no presenta nulos en campos clave, mantiene identificadores únicos, respeta rangos numéricos válidos y conserva categorías controladas para campos como canal, nivel de servicio y riesgo operativo.

Esta evidencia demuestra que la validación de calidad no se limita a la capa RAW. El proyecto aplica un segundo control sobre el dato ya transformado, con el objetivo de comprobar que las correcciones realizadas por Spark han producido una salida coherente, completa y apta para explotación analítica.

Desde el punto de vista del pipeline, este ruleset actúa como control de aceptación de la capa TRUSTED antes de su consulta en Athena y su consumo posterior en Power BI.

Figura 25. Resultado final de AWS Glue Data Quality sobre la capa TRUSTED



La captura muestra el resultado de la evaluación de calidad aplicada sobre la tabla `trusted_oficinas` en AWS Glue Data Quality. El ruleset `dq_trusted_oficinas` finaliza con estado **Completed** y obtiene una puntuación de calidad del **100%**, superando **62 de 62 reglas**.

Esta evidencia confirma que la capa TRUSTED cumple íntegramente las validaciones definidas para explotación analítica. A diferencia de la capa RAW, donde la evaluación detectó incidencias y arrojó un resultado fallido, la capa TRUSTED supera completamente los controles de estructura, completitud, unicidad, rangos válidos y consistencia de negocio.

El resultado constituye una prueba objetiva de que el job de Glue Spark ha corregido los problemas detectados en la fase inicial de calidad. De este modo, el pipeline no solo identifica errores en el dato bruto, sino que los transforma en una salida fiable, apta para consulta en Athena y consumo posterior en Power BI.

La validación final con score del 100% actúa como evidencia de aceptación de la capa TRUSTED dentro del flujo batch del proyecto.

Extracto representativo del ruleset TRUSTED

El ruleset aplicado sobre TRUSTED valida tanto la estructura del dataset final como la calidad de los campos necesarios para explotación analítica.

```
Rules = [  
  ColumnExists "registro_id",  
  ColumnExists "mes",  
  ColumnExists "oficina_id",
```

ColumnExists "oficina",
 ColumnExists "provincia",
 ColumnExists "comunidad_autonoma",
 ColumnExists "zona_operativa",
 ColumnExists "canal_principal",
 ColumnExists "prioridad_media_expedientes",
 ColumnExists "expedientes_recibidos",
 ColumnExists "expedientes_resueltos",
 ColumnExists "documentacion_pendiente",
 ColumnExists "incidencias_abiertas",
 ColumnExists "tiempo_medio_espera_min",
 ColumnExists "nivel_servicio",
 ColumnExists "satisfaccion_media",
 ColumnExists "tasa_resolucion_pct",
 ColumnExists "ratio_incidencias_pct",
 ColumnExists "riesgo_operativo",

 IsComplete "registro_id",
 IsComplete "mes",
 IsComplete "oficina_id",
 IsComplete "oficina",
 IsComplete "provincia",
 IsComplete "expedientes_recibidos",
 IsComplete "expedientes_resueltos",
 IsComplete "tiempo_medio_espera_min",

 IsUnique "registro_id",

 ColumnValues "expedientes_recibidos" >= 0,
 ColumnValues "expedientes_resueltos" >= 0,
 ColumnValues "documentacion_pendiente" >= 0,
 ColumnValues "incidencias_abiertas" >= 0,
 ColumnValues "tiempo_medio_espera_min" >= 0,

 ColumnValues "satisfaccion_media" between 1 and 5,
 ColumnValues "tasa_resolucion_pct" between 0 and 100,
 ColumnValues "ratio_incidencias_pct" >= 0,
 ColumnValues "riesgo_operativo" in ["bajo", "medio", "alto"]

]

Este extracto muestra que la validación final no se limita a comprobar columnas existentes. También evalúa completitud, unicidad, valores no negativos, rangos válidos, tasas calculadas y categorías de riesgo operativo.

Controles finales de calidad

Control final	Resultado esperado	Estado
Filas en TRUSTED	96	Cumple
Duplicados en registro_id	0	Cumple
Nulos en campos clave	0	Cumple
Métricas negativas	0	Cumple
Satisfacción fuera del rango 1-5	0	Cumple
Tasa de resolución fuera del rango 0-100	0	Cumple
Casos con expedientes resueltos superiores a recibidos	0	Cumple

Interpretación de la validación final

El resultado de la evaluación final demuestra que el pipeline ha corregido los problemas detectados en la capa RAW y ha generado una capa TRUSTED apta para explotación analítica.

La mejora es clara: la capa RAW obtuvo una evaluación fallida, mientras que la capa TRUSTED alcanza un resultado completo de calidad. Esta comparación permite defender que el proyecto no solo detecta errores, sino que también los corrige mediante un proceso reproducible en Glue Spark.

Con esta validación, la capa TRUSTED queda preparada para las siguientes fases del proyecto: catalogación final, consulta SQL en Athena, generación de salidas ANALYTICS y consumo visual en Power BI.


15. Amazon Athena: validación y explotación SQL

Amazon Athena actúa como capa de consulta SQL sobre los datos almacenados en Amazon S3 y catalogados mediante AWS Glue Data Catalog. Su función dentro del proyecto es doble: por un lado, permite validar técnicamente las salidas generadas por el pipeline; por otro, permite explotar indicadores de negocio antes de su visualización final en Power BI.

Durante la ejecución del laboratorio, Athena consultó las tablas reales registradas por Glue Data Catalog, entre ellas `trusted_oficinas`, `analytics_kpis_oficina`, `analytics_kpis_provincia` y `analytics_resumen`. Estas tablas proceden de las rutas `trusted/` y `analytics/` del bucket S3 del proyecto.

Athena se utiliza como punto de control entre la transformación Spark y el dashboard final. Antes de construir visualizaciones, se comprueban filas, nulos, rangos, agregados y KPIs mediante SQL. Esto evita que Power BI se convierta en la única fuente de validación y refuerza la trazabilidad del resultado.

Figura 26. Configuración de resultados de consulta en Amazon Athena




La captura muestra la configuración de Amazon Athena utilizada durante el proyecto. En ella se define la ubicación donde se almacenan los resultados de las consultas SQL: `s3://proyecto-bigdata-oficinas-selma-202506/athena-results/`.

Esta configuración es necesaria para ejecutar consultas en Athena, ya que el servicio guarda los resultados de cada ejecución en una ruta de Amazon S3. De este modo, las consultas realizadas durante la validación del proyecto quedan integradas dentro del mismo Data Lake.

Desde el punto de vista arquitectónico, esta evidencia conecta Athena con la estructura general del bucket. Los datos RAW, las salidas TRUSTED, las salidas ANALYTICS, los resultados de calidad y los resultados SQL quedan organizados dentro de un mismo entorno de almacenamiento.

Esta captura acredita la preparación del entorno de consulta. Las evidencias posteriores muestran la ejecución real de consultas sobre las tablas catalogadas por Glue Data Catalog, como `trusted_oficinas`, `analytics_kpis_oficina`, `analytics_kpis_provincia` y `analytics_resumen`.

Figura 27. Base de datos y tablas disponibles en Amazon Athena



La captura muestra el editor de consultas de Amazon Athena configurado sobre la base de datos `proyecto_bigdata_oficinas`. En el panel lateral se observan las tablas disponibles para consulta, entre ellas `trusted_oficinas`, `analytics_kpis_oficina`, `analytics_kpis_provincia`, `analytics_resumen` y `oficinas`.

Esta evidencia confirma que las salidas generadas y catalogadas en las fases anteriores del pipeline están correctamente disponibles en Athena como tablas consultables. En particular, la presencia de `trusted_oficinas` permite realizar validaciones técnicas sobre la capa depurada, mientras que las tablas analíticas permiten ejecutar consultas de negocio sobre oficina, provincia y resumen ejecutivo.

Desde el punto de vista del proyecto, esta captura representa el punto de unión entre la ingeniería del dato y su explotación analítica. Los resultados ya no se encuentran únicamente como ficheros en S3 o como tablas catalogadas en Glue, sino como estructuras directamente consultables mediante SQL.

Esta disponibilidad en Athena es la base para validar los KPIs del proyecto, contrastar resultados con Power BI y justificar que el dashboard final se apoya en datos previamente procesados y verificados.

15.1. Tipos de consultas realizadas

Tipo de consulta	Objetivo
Validación técnica	Comprobar número de filas, duplicados, nulos, métricas negativas y coherencia final de la capa TRUSTED.
Resumen ejecutivo	Leer la tabla analytics_resumen para contrastar los KPIs globales del proyecto.
Ranking por oficina	Identificar oficinas con mayor carga de trabajo, más incidencias o mayor riesgo operativo.
KPIs por provincia	Comparar el rendimiento territorial mediante la tabla analytics_kpis_provincia.
Evolución mensual	Analizar tendencias temporales de expedientes, resolución, incidencias, espera y satisfacción.
Contraste con Power BI	Validar que los KPIs mostrados en el dashboard coinciden con los resultados obtenidos por SQL.

15.2. SQL representativo de Athena

En la memoria se incluye un extracto representativo de las consultas utilizadas. El bloque completo de SQL se conserva como evidencia técnica en la carpeta 05_athena/.

```
USE proyecto_bigdata_oficinas;

SELECT *
FROM analytics_resumen;

SELECT
  oficina_id,
  oficina,
  provincia,
  SUM(expedientes_recibidos) AS expedientes_recibidos_total,
  SUM(expedientes_resueltos) AS expedientes_resueltos_total,
  SUM(incidencias_abiertas) AS incidencias_abiertas_total,
  ROUND(SUM(expedientes_resueltos) * 100.0 / SUM(expedientes_recibidos), 2) AS tasa_resolucion_pct,
  ROUND(AVG(tiempo_medio_espera_min), 1) AS espera_media_min,
  ROUND(AVG(satisfaccion_media), 2) AS satisfaccion_media
FROM trusted_oficinas
GROUP BY oficina_id, oficina, provincia
ORDER BY expedientes_recibidos_total DESC;

SELECT 'filas_trusted' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas

UNION ALL


SELECT 'registros_con_nulos_clave' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas
WHERE registro_id IS NULL
  OR mes IS NULL
  OR oficina_id IS NULL
  OR oficina IS NULL
  OR provincia IS NULL
  OR expedientes_recibidos IS NULL

UNION ALL

SELECT 'registros_con_metricas_negativas' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas
WHERE expedientes_recibidos < 0
  OR expedientes_resueltos < 0
  OR documentacion_pendiente < 0
  OR incidencias_abiertas < 0
  OR tiempo_medio_espera_min < 0;
```

Este bloque resume las tres funciones principales de Athena en el proyecto: lectura del resumen ejecutivo, explotación de KPIs por oficina y validación técnica de la capa TRUSTED.

Figura 28. Validación técnica final de la capa TRUSTED en Amazon Athena




La figura muestra la ejecución en Amazon Athena de una consulta SQL orientada a la validación técnica de la tabla trusted_oficinas. La consulta comprueba cuatro condiciones clave del dataset final: el número total de filas, la ausencia de nulos en campos esenciales, la inexistencia de métricas negativas y la coherencia entre expedientes recibidos y expedientes resueltos.

El resultado obtenido confirma que la capa TRUSTED contiene **96 registros**, no presenta registros con nulos en campos clave, no contiene métricas negativas y no existen casos en los que los expedientes resueltos superen a los expedientes recibidos.

Esta evidencia es especialmente importante porque aporta una validación independiente mediante SQL, complementaria a la validación realizada con AWS Glue Data Quality. De este modo, la calidad del dataset final no queda justificada por una única herramienta, sino por dos mecanismos distintos: reglas de calidad en Glue y contraste analítico en Athena.

Desde el punto de vista del proyecto, la consulta confirma que la tabla trusted_oficinas es coherente y apta para explotación analítica. Esto permite utilizarla con confianza tanto para generar agregados de negocio como para alimentar el dashboard final en Power BI.

Figura 29. Consulta de KPIs provinciales en Amazon Athena



La figura muestra la ejecución en Amazon Athena de una consulta SQL sobre la tabla analytics_kpis_provincia. La consulta agrega y ordena indicadores por provincia, incluyendo expedientes recibidos, expedientes


resueltos, incidencias abiertas, documentación pendiente, tasa de resolución, ratio de incidencias, espera media y satisfacción media.

El resultado permite comparar el comportamiento operativo entre territorios. En la salida se observan provincias como Madrid, Sevilla, Valencia y Barcelona, cada una con sus indicadores agregados, lo que facilita identificar diferencias en volumen de actividad, eficiencia y calidad del servicio.

Esta evidencia demuestra que Athena no se utiliza únicamente para validaciones técnicas, sino también como herramienta de análisis de negocio. La tabla `analytics_kpis_provincia`, generada previamente en la capa ANALYTICS por el job de Glue Spark, puede ser consultada directamente para obtener una lectura territorial consolidada.

Desde el punto de vista del proyecto, esta consulta enlaza la ingeniería del dato con la interpretación operativa. Los resultados obtenidos sirven como base para construir visualizaciones comparativas por provincia en Power BI y refuerzan que la arquitectura diseñada no solo corrige y almacena datos, sino que también los convierte en información útil para la toma de decisiones.

Figura 30. Consulta de riesgo operativo por oficina en Amazon Athena



La figura muestra una consulta ejecutada en Amazon Athena sobre la tabla `trusted_oficinas`, orientada a identificar oficinas con mayor riesgo operativo. La consulta calcula el número de meses clasificados como riesgo alto, medio y bajo, y combina este análisis con indicadores como tasa de resolución media, ratio de incidencias, espera media y satisfacción media.

El resultado devuelve las ocho oficinas del caso de uso y permite priorizar aquellas que acumulan más meses de riesgo alto o presentan peores indicadores asociados. Esta lectura es especialmente útil porque no se limita a medir volumen de expedientes, sino que relaciona riesgo, eficiencia y calidad del servicio.

Desde el punto de vista técnico, la consulta demuestra que la capa TRUSTED puede explotarse mediante SQL para responder preguntas de negocio. Desde el punto de vista de gestión, permite detectar qué oficinas deberían revisarse con mayor prioridad antes de trasladar el análisis al dashboard de Power BI.

Esta evidencia refuerza el valor de Athena como capa intermedia entre el procesamiento Spark y la visualización final: valida los datos, permite explorarlos con SQL y genera resultados interpretables para la toma de decisiones.

15.3. Valor de Athena dentro del pipeline

Athena permite comprobar que las salidas generadas por Glue Spark son coherentes antes de utilizarlas en Power BI. Esta validación SQL aporta una capa adicional de confianza, ya que los principales indicadores pueden justificarse mediante consultas reproducibles sobre tablas catalogadas en AWS Glue Data Catalog.

De esta forma, el flujo queda cerrado de manera trazable: Glue Spark genera las salidas, Glue Data Catalog las registra, Athena las valida mediante SQL y Power BI las convierte en visualización ejecutiva orientada a la toma de decisiones.

16. Power BI: modelo, dashboard e insights

Power BI se utiliza como capa final de visualización ejecutiva y autoservicio para usuarios de negocio. Su función dentro del proyecto no es limpiar ni transformar el dato bruto, sino convertir las salidas ya procesadas, validadas y contrastadas en indicadores comprensibles para la toma de decisiones.

La transformación principal del dato se realiza previamente en AWS mediante Glue Spark, Glue Data Quality y Athena. De este modo, Power BI consume información preparada desde la capa TRUSTED y desde las salidas ANALYTICS, evitando trasladar la lógica de limpieza al informe visual. Esta decisión mejora la trazabilidad del proyecto, reduce el riesgo de cálculos inconsistentes y permite justificar cada KPI mostrado en el dashboard a partir del pipeline cloud construido en AWS.

El dashboard se diseña con un enfoque ejecutivo-operativo. En la parte superior se presentan los indicadores principales del servicio; en la zona central se analiza la evolución mensual, el riesgo operativo y la comparación territorial; y en la zona inferior se incorpora una tabla de detalle para priorizar oficinas según carga, incidencias, espera, satisfacción y nivel de riesgo.

El objetivo de esta capa no es únicamente presentar gráficos, sino transformar los resultados técnicos del pipeline en una herramienta de lectura directiva. Power BI permite responder preguntas clave del caso de uso: qué oficinas concentran más presión operativa, qué provincias presentan mayor carga, cómo evoluciona la resolución mensual, dónde aparecen más incidencias y qué unidades requieren seguimiento prioritario.

16.1. Modelo de datos utilizado en Power BI

El informe de Power BI se alimenta de las salidas finales generadas por el pipeline batch. La tabla `oficinas_empleo_trusted_2025` actúa como base principal del modelo, ya que contiene el dato limpio, normalizado y enriquecido a grano mensual por oficina. A partir de ella se construyen los indicadores principales, los filtros y el ranking operativo.

Además, el modelo incorpora las salidas analíticas `kpis_mensuales_por_oficina_2025`, `kpis_mensuales_por_provincia_2025` y `resumen_ejecutivo_2025`, generadas previamente en la capa ANALYTICS. Estas tablas permiten contrastar los KPIs agregados y mantener continuidad con las validaciones realizadas en Athena.

La decisión de trabajar sobre TRUSTED y ANALYTICS evita cargar en Power BI el dataset RAW con errores. De este modo, el dashboard se apoya en datos ya procesados, validados y trazables, manteniendo separadas las fases de limpieza, cálculo y visualización.

16.2. Medidas DAX y KPIs principales

Para construir el dashboard se definieron medidas DAX orientadas a indicadores de gestión. Estas medidas permiten calcular expedientes recibidos, expedientes resueltos, tasa de resolución, incidencias, espera media, satisfacción y puntuación de riesgo operativo.

KPI / medida	Finalidad dentro del dashboard
Total Expedientes Recibidos	Medir la carga operativa total o filtrada por provincia/riesgo.
Total Expedientes Resueltos	Evaluar la capacidad de cierre de expedientes.
Tasa Resolución %	Comparar eficiencia operativa entre oficinas y territorios.
Incidencias Abiertas	Detectar presión administrativa o problemas pendientes.
Espera Media Min	Medir calidad del servicio desde la perspectiva del ciudadano.
Satisfacción Media	Evaluar percepción del servicio prestado.
Meses Riesgo Alto	Identificar oficinas con recurrencia de situaciones críticas.

Puntuación Riesgo Operativo Ordenar oficinas según prioridad de seguimiento.


Estas medidas convierten el dataset procesado en indicadores interpretables por usuarios de negocio. Además, permiten que los filtros del dashboard recalculen automáticamente los resultados según provincia o nivel de riesgo operativo.

Figura 31. Dashboard ejecutivo final en Power BI



La figura muestra el dashboard ejecutivo desarrollado en Power BI a partir de las capas TRUSTED y ANALYTICS generadas en AWS. El informe integra filtros por provincia y riesgo operativo, tarjetas KPI, evolución mensual, comparación territorial, distribución de riesgo y ranking de oficinas críticas.

Figura 32. Evidencia de construcción del dashboard en Power BI Desktop



La captura muestra el dashboard dentro de Power BI Desktop, con la interfaz de edición visible, el panel de visualizaciones y el panel de datos del modelo. Esta evidencia confirma que el cuadro de mando fue construido directamente en Power BI y no corresponde a una imagen externa o a una maqueta.

En el panel de datos se observan las tablas utilizadas en el informe, procedentes de las salidas generadas por el pipeline batch: `oficinas_empleo_trusted_2025`, `kpis_mensuales_por_oficina_2025`, `kpis_mensuales_por_provincia_2025` y `resumen_ejecutivo_2025`. Estas tablas conectan la capa visual con las salidas TRUSTED y ANALYTICS generadas previamente en AWS.

La evidencia también permite observar las medidas empleadas para construir los KPIs y visuales del dashboard, como expedientes recibidos, expedientes resueltos, tasa de resolución, incidencias, espera media, satisfacción y métricas de riesgo operativo.

Figura 33. Explotación interactiva del dashboard mediante filtro territorial



La figura muestra el comportamiento interactivo del dashboard al aplicar el filtro de provincia sobre Valencia. Al seleccionar este territorio, todos los elementos del informe se recalculan automáticamente: tarjetas KPI, evolución mensual, distribución por riesgo operativo, gráfico territorial y ranking de oficinas críticas.

Para Valencia, el panel muestra aproximadamente 46 mil expedientes recibidos, 41 mil expedientes resueltos, una tasa de resolución del 89,02%, alrededor de 1 mil incidencias abiertas, una espera media de 45,33 minutos y una satisfacción media de 3,45. Esta lectura permite analizar la situación de una provincia concreta sin modificar el modelo de datos ni crear consultas adicionales.

La tabla inferior reduce el análisis a las oficinas de Valencia, diferenciando entre Oficina Empleo Levante y Oficina Empleo Valencia. Esta vista permite comparar ambas unidades a partir de expedientes recibidos, expedientes resueltos, tasa de resolución, incidencias, espera media, satisfacción, meses de riesgo alto y puntuación de riesgo operativo.

Esta evidencia confirma que Power BI funciona como una herramienta de autoservicio analítico. El dashboard no es una imagen estática, sino una aplicación interactiva capaz de recalculando los indicadores según el territorio o nivel de riesgo seleccionado.

16.3. Interpretación ejecutiva de los resultados

El dashboard permite transformar los resultados técnicos del pipeline en una lectura operativa orientada a la toma de decisiones. La vista general consolida la actividad anual de las oficinas de empleo analizadas durante 2025, mostrando aproximadamente 191 mil expedientes recibidos, 167 mil expedientes resueltos y una tasa global de resolución del 87,44%.

Estos indicadores reflejan que el sistema mantiene una capacidad de resolución elevada, aunque no completa. La diferencia entre expedientes recibidos y resueltos muestra que existe una carga pendiente que debe seguirse desde una perspectiva operativa. Por este motivo, el análisis no puede limitarse únicamente al volumen total de expedientes, sino que debe completarse con indicadores de incidencias, tiempo de espera, satisfacción ciudadana y riesgo operativo.

Desde el punto de vista territorial, el gráfico de carga operativa muestra que Madrid concentra el mayor volumen de expedientes recibidos, seguida de Sevilla, Valencia y Barcelona. Esta información permite identificar dónde se concentra la mayor presión del servicio. Sin embargo, el volumen no debe interpretarse de forma aislada: una provincia con mayor actividad no necesariamente es la más crítica si mantiene niveles aceptables de resolución, incidencias y satisfacción.

La distribución por riesgo operativo muestra que la categoría alto tiene un peso relevante dentro del conjunto analizado. Esta lectura convierte el riesgo en un indicador de alerta temprana, ya que permite identificar meses y oficinas donde pueden coincidir mayor presión asistencial, más incidencias, tiempos de espera elevados o menor eficiencia en la resolución de expedientes.

La tabla inferior aporta la lectura más accionable del dashboard. El ranking de oficinas críticas combina carga operativa, expedientes resueltos, tasa de resolución, incidencias abiertas, espera media, satisfacción, meses de riesgo alto y puntuación de riesgo operativo. Esta combinación permite priorizar oficinas no solo por volumen, sino por criticidad real. En la vista general, la Oficina Empleo Sevilla aparece como una de las unidades que requiere mayor seguimiento, al situarse en la parte superior del ranking de riesgo operativo.

La vista filtrada por Valencia demuestra el valor interactivo del informe. Al seleccionar esta provincia, el dashboard recalcula automáticamente todos los indicadores y permite analizar el comportamiento específico del territorio. En este caso, Valencia presenta aproximadamente 46 mil expedientes recibidos, 41 mil expedientes resueltos y una tasa de resolución del 89,02%, superior a la media global. Sin embargo, también muestra una espera media de 45,33 minutos, superior al promedio general, lo que indica que una buena tasa de resolución no elimina la necesidad de revisar la calidad percibida y los tiempos de atención. En conjunto, Power BI permite pasar de una lectura técnica del dato a una lectura de gestión. El dashboard responde a preguntas clave del caso de uso: qué territorios concentran más carga, cómo evoluciona la actividad mensual, qué nivel de riesgo predomina, qué oficinas requieren seguimiento prioritario y cómo cambian los indicadores al aplicar filtros territoriales.

16.4. Conclusiones obtenidas a partir del dashboard.

A partir del dashboard desarrollado en Power BI se obtienen las siguientes conclusiones principales:

- 1. La red analizada mantiene una capacidad de resolución sólida, aunque no completa.**
El panel consolida aproximadamente 191 mil expedientes recibidos y 167 mil expedientes resueltos durante 2025, con una tasa global de resolución del 87,44%. Este resultado muestra un nivel de eficiencia relevante, pero también evidencia que existe una diferencia entre carga recibida y carga resuelta que debe mantenerse bajo seguimiento.
- 2. Madrid concentra la mayor presión territorial del sistema.**
El gráfico de carga operativa por provincia muestra que Madrid es el territorio con mayor volumen de expedientes recibidos. Esta lectura permite identificar dónde se concentra una parte significativa de la actividad y dónde conviene prestar especial atención desde el punto de vista de recursos, capacidad y seguimiento operativo.
- 3. El riesgo operativo aporta una lectura más útil que el volumen por sí solo.**
La distribución por riesgo muestra que la categoría de riesgo alto tiene un peso relevante dentro del conjunto analizado. Esto permite detectar situaciones críticas que podrían quedar ocultas si solo se analizasen expedientes recibidos o expedientes resueltos. El riesgo operativo funciona como indicador de alerta temprana para priorizar oficinas y meses que requieren revisión.
- 4. El ranking de oficinas críticas convierte el dashboard en una herramienta de decisión.**
La tabla inferior permite ordenar las oficinas combinando carga, tasa de resolución, incidencias abiertas, espera media, satisfacción, meses de riesgo alto y puntuación de riesgo operativo. Esta

combinación evita tomar decisiones basadas únicamente en volumen y permite identificar unidades que requieren seguimiento prioritario. En la vista general, la Oficina Empleo Sevilla aparece en la parte superior del ranking, por lo que debe considerarse una oficina prioritaria para análisis.

5. **La interacción mediante filtros permite pasar de una visión global a una lectura territorial.**

La vista filtrada por Valencia demuestra que el dashboard recalcula automáticamente los indicadores al seleccionar una provincia. Esta funcionalidad permite analizar un territorio concreto sin rehacer consultas ni modificar el modelo. En el caso de Valencia, se observa una tasa de resolución superior a la media global, pero una espera media también superior, lo que confirma la importancia de analizar conjuntamente eficiencia y calidad del servicio.

6. **Power BI actúa como capa final de explotación, no como herramienta de limpieza.**

El informe se apoya en datos previamente procesados, validados y contrastados en AWS. Esta separación refuerza la trazabilidad del proyecto: Glue Spark transforma, Glue Data Quality valida, Athena contrasta con SQL y Power BI convierte los resultados en información comprensible para usuarios de negocio.

En conjunto, el dashboard permite responder preguntas de gestión relevantes: qué provincias concentran mayor carga, cómo evoluciona la actividad mensual, qué nivel de riesgo predomina, qué oficinas requieren seguimiento y cómo cambian los indicadores al aplicar filtros territoriales. Por tanto, Power BI cierra el pipeline batch convirtiendo los datos técnicos en una herramienta visual orientada a la toma de decisiones.

16.5. Valor aportado por Power BI al proyecto

La incorporación de Power BI aporta valor al proyecto porque permite que los resultados del pipeline Big Data sean interpretables por perfiles no técnicos. Mientras que AWS proporciona almacenamiento, calidad, transformación y consulta, Power BI traduce esos resultados en un cuadro de mando ejecutivo.

El valor principal del dashboard no está únicamente en mostrar indicadores, sino en permitir la exploración interactiva del servicio. Los filtros, las tarjetas KPI, los gráficos y el ranking de oficinas facilitan una lectura rápida del estado general y permiten profundizar en territorios o unidades concretas.

De este modo, la solución final no se limita a demostrar una arquitectura cloud funcional, sino que completa el ciclo de vida del dato: desde la ingesta y depuración hasta la explotación visual orientada a decisiones operativas.

17. Resultados e interpretación de negocio

Los resultados finales del proyecto permiten evaluar la actividad operativa de las oficinas de empleo desde cinco dimensiones principales: carga de trabajo, capacidad de resolución, incidencias abiertas, tiempo medio de espera y satisfacción ciudadana. La capa analítica generada en AWS y explotada en Power BI permite pasar de una visión técnica del dato a una lectura orientada a la gestión.

La tasa de resolución utilizada en esta sección se calcula como indicador agregado, dividiendo los expedientes resueltos totales entre los expedientes recibidos totales. Esta decisión evita promediar porcentajes mensuales y permite interpretar la eficiencia real de cada oficina o provincia sobre su volumen total de actividad.

17.1. Oficinas con mayor carga operativa

Oficina	Provincia	Expedientes recibidos	Expedientes resueltos	Tasa resolución	Espera media	Satisfacción media
Oficina Empleo Norte	Madrid	26.155	23.576	90,14%	43,7	3,47
Oficina Empleo Sur	Madrid	25.567	23.281	91,06%	44,1	3,20
Oficina Empleo Sevilla	Sevilla	25.336	19.327	76,28%	40,7	3,47
Oficina Empleo Andalucía	Sevilla	24.542	21.380	87,12%	27,6	3,65
Oficina Empleo Centro	Madrid	24.504	21.260	86,76%	46,7	2,80

La lectura por oficina muestra que las unidades con mayor carga no presentan necesariamente el mismo comportamiento operativo. Las oficinas Norte y Sur de Madrid concentran un volumen elevado de expedientes y mantienen tasas de resolución superiores al 90%, lo que indica una capacidad de respuesta sólida pese a la presión de entrada.

En cambio, la Oficina Empleo Sevilla destaca como caso prioritario de análisis, ya que combina un volumen alto de expedientes recibidos con una tasa de resolución sensiblemente inferior al resto de oficinas

principales. Esta combinación sugiere una posible tensión entre carga de trabajo, capacidad de cierre e incidencias operativas.

La Oficina Empleo Centro también requiere seguimiento, no tanto por volumen total, sino por su espera media elevada. Este resultado confirma que la evaluación del servicio no debe basarse únicamente en expedientes recibidos o resueltos, sino en una combinación de eficiencia, tiempos de atención y percepción ciudadana.

17.2. Comparación territorial por provincia

Provincia	Comunidad autónoma	Expedientes recibidos	Expedientes resueltos	Incidencias	Tasa resolución	Espera media
Madrid	Comunidad de Madrid	76.226	68.117	1.738	89,36%	44,8
Sevilla	Andalucía	49.878	40.707	1.338	81,61%	34,2
Valencia	Comunidad Valenciana	45.684	40.666	1.058	89,02%	45,3
Barcelona	Cataluña	19.531	17.796	625	91,12%	44,1

La comparación territorial muestra que Madrid concentra la mayor carga agregada del sistema, con más de 76 mil expedientes recibidos. Esto la convierte en el territorio con mayor presión operativa en términos de volumen y en un ámbito prioritario para seguimiento de capacidad.

Sevilla presenta una lectura diferente. Aunque no es la provincia con mayor carga, muestra la tasa de resolución más baja del conjunto y acumula un volumen relevante de incidencias. Desde el punto de vista de gestión, esto la convierte en candidata prioritaria para revisión operativa, especialmente en procesos de cierre de expedientes y gestión de incidencias.

Valencia mantiene una tasa de resolución cercana al comportamiento de Madrid, pero presenta una espera media elevada. Esta situación demuestra que una tasa de resolución aceptable no garantiza por sí sola una buena experiencia de atención. Por tanto, conviene analizar conjuntamente resolución, espera y satisfacción.

Barcelona presenta el menor volumen de expedientes, pero la tasa de resolución más alta. Esta lectura sugiere una presión operativa menor y una capacidad de cierre proporcionalmente más favorable dentro del conjunto analizado.

17.3. Lectura ejecutiva de los resultados

Los resultados permiten extraer una conclusión importante: la priorización no debe basarse únicamente en el volumen de expedientes. Una oficina o provincia puede tener una carga elevada y, aun así, mantener buenos niveles de resolución. Por el contrario, una unidad con menor volumen puede requerir seguimiento si combina baja resolución, incidencias abiertas, espera elevada o varios meses en riesgo alto.

El indicador riesgo_operativo aporta valor porque integra distintas señales de posible degradación del servicio. Su uso permite pasar de un análisis descriptivo a un análisis de priorización, identificando qué oficinas deberían revisarse antes desde el punto de vista operativo.

La tabla de oficinas críticas del dashboard refuerza esta lectura. El ranking no se construye únicamente con expedientes recibidos, sino combinando carga, resolución, incidencias, espera media, satisfacción, meses de riesgo alto y puntuación de riesgo operativo. Esto permite identificar unidades que requieren seguimiento prioritario con un criterio más completo.

La separación entre capas también refuerza la fiabilidad del análisis. Los resultados no se calculan sobre el dato bruto, sino sobre datos procesados en Glue Spark, validados con Glue Data Quality, contrastados en Athena y visualizados en Power BI. Esta trazabilidad permite defender que los indicadores finales no son cálculos aislados del dashboard, sino el resultado de un pipeline completo de Big Data.

17.4. Decisiones operativas sugeridas

Hallazgo	Interpretación	Acción sugerida
Madrid concentra el mayor volumen de expedientes	Existe una presión territorial elevada por carga de entrada.	Mantener seguimiento de capacidad, recursos disponibles y evolución mensual.
Sevilla presenta la menor tasa de resolución provincial	Puede existir tensión entre carga, recursos y capacidad de cierre.	Revisar procesos internos, causas de retraso e incidencias recurrentes.

Oficina Empleo Sevilla combina volumen alto y baja resolución	Es una unidad prioritaria dentro del ranking operativo.	Analizar expedientes pendientes, incidencias y posibles cuellos de botella.
Valencia presenta espera media elevada	La resolución puede ser aceptable, pero la experiencia de atención puede verse afectada.	Revisar tiempos de atención y distribución de carga mensual.
Oficinas con alta puntuación de riesgo	La criticidad no depende solo del volumen, sino de varias señales combinadas.	Priorizar seguimiento de oficinas con más meses de riesgo alto.
Incidencias abiertas relevantes	Las incidencias pueden afectar a la eficiencia operativa y a la satisfacción.	Crear seguimiento específico de incidencias por oficina y mes.

Estas acciones convierten el resultado analítico en una herramienta de apoyo a la decisión. El proyecto no se limita a describir datos históricos, sino que permite orientar medidas de mejora sobre territorios y oficinas concretas.

17.5. Síntesis final de negocio

En conjunto, el análisis confirma que la solución permite identificar patrones relevantes para la gestión operativa. Madrid concentra la mayor carga territorial, Sevilla presenta señales de menor eficiencia relativa, Valencia combina buena resolución con espera elevada y el ranking de oficinas permite priorizar unidades críticas con mayor precisión que un análisis basado únicamente en volumen.

La principal aportación del proyecto es convertir datos operativos dispersos en información gobernada, validada y accionable. Gracias al flujo batch construido en AWS y a la explotación final en Power BI, el análisis permite responder preguntas de negocio concretas: dónde se concentra la carga, qué oficinas presentan más riesgo, qué territorios requieren seguimiento y qué indicadores deben vigilarse para mejorar el servicio.

18. Seguridad, gobernanza, coste y rendimiento

Aunque el proyecto se ejecuta en un entorno académico de AWS Academy / Learner Lab, el diseño incorpora criterios extrapolables a un entorno profesional. La arquitectura se ha planteado con separación de capas, control de calidad, uso de roles gestionados, catalogación de metadatos y consumo analítico sobre datos preparados.

Área	Aplicación en el proyecto	Valor aportado
Almacenamiento S3	Organización del Data Lake por zonas RAW, TRUSTED, ANALYTICS, scripts, resultados de calidad y resultados Athena.	Mejora la trazabilidad y evita mezclar datos brutos con datos procesados.
Control de acceso	Uso del rol LabRole proporcionado por AWS Academy.	Permite ejecutar Glue y acceder a S3 dentro de los límites del laboratorio.
Gobierno del dato	Uso de AWS Glue Data Catalog como catálogo central de metadatos.	Permite que Glue, Athena y Data Quality trabajen sobre tablas reconocibles.
Calidad de datos	Rulesets aplicados sobre RAW y TRUSTED.	Convierte la calidad en una fase explícita, medible y documentada del pipeline.
Separación de capas	RAW conserva el dato original, TRUSTED publica dato depurado y ANALYTICS ofrece salidas de consumo.	Refuerza el linaje del dato y facilita explicar el origen de cada KPI.
Power BI sobre datos finales	El dashboard consume datos ya procesados y contrastados.	Evita trasladar la limpieza del dato al informe visual.

Optimización y rendimiento

Aspecto	Recomendación
Formato de almacenamiento	CSV es adecuado para el laboratorio, pero en producción sería recomendable utilizar Parquet por rendimiento y reducción de coste en consulta.
Particionado	En un entorno real, las capas TRUSTED y ANALYTICS podrían particionarse por año, mes o provincia.

Athena	Conviene reducir columnas escaneadas y consultar tablas analíticas ya preparadas, no RAW completo.
Glue Spark	En laboratorio se utilizan recursos mínimos; en producción se ajustarían workers y configuración según volumen real.
Resultados temporales	athena-results/ y dq-results/ podrían gestionarse mediante reglas de ciclo de vida en S3 para evitar acumulación innecesaria.
Redshift no utilizado	No se emplea Redshift porque Athena resulta suficiente para un dataset académico, reduce complejidad y evita la gestión de clústeres.

Esta sección muestra que el proyecto no solo funciona, sino que ha sido diseñado con criterios de gobierno, coste y escalabilidad razonables para el contexto académico.

19. Riesgos, limitaciones y mitigaciones

Durante la ejecución del proyecto se han identificado riesgos habituales en laboratorios cloud y proyectos de datos. La siguiente tabla resume los principales riesgos y las medidas aplicadas o previstas para mitigarlos.

Riesgo o limitación	Probabilidad	Impacto	Mitigación aplicada o propuesta
Los crawlers de Glue generan nombres de tabla distintos a los nombres de CSV	Media	Puede crear confusión en Athena y documentación.	Documentar los nombres reales usados en Athena y mantener los nombres largos como referencia de ficheros.
Glue Data Quality no acepta una regla avanzada o mal planteada	Media	Puede producir fallos no relacionados con la calidad real.	Ajustar reglas al significado funcional de cada campo; no aplicar unicidad a métricas que pueden repetirse.
El job Spark falla por rutas S3 incorrectas	Media	Detiene la generación de TRUSTED y ANALYTICS.	Parametrizar rutas y validarlas antes de ejecutar el job.
Athena no tiene ruta de resultados configurada	Alta	Impide ejecutar consultas.	Configurar athena-results/ dentro del bucket del proyecto antes de consultar.
Power BI no coincide con Athena	Media	Reduce confianza en el dashboard.	Validar KPIs principales contra analytics_resumen y consultas SQL en Athena.

Reset del laboratorio	Alta	Puede eliminar recursos y evidencias.	No resetear el laboratorio antes de la revisión; conservar capturas y ZIP local del proyecto.
Uso de CSV en lugar de Parquet	Baja en laboratorio, media en producción	Mayor coste de consulta y menor rendimiento.	Mantener CSV en laboratorio por simplicidad; proponer Parquet como mejora futura.

Estas limitaciones no invalidan el proyecto. Al contrario, documentarlas refuerza la memoria porque demuestra control sobre problemas reales de ejecución, inferencia de esquemas, calidad, rutas y consumo analítico.

20. Conclusiones y mejoras futuras

El proyecto demuestra una arquitectura Big Data batch completa sobre AWS, con almacenamiento en S3, catalogación mediante AWS Glue Data Catalog, validación con AWS Glue Data Quality, procesamiento distribuido con Glue Spark, explotación SQL con Athena y visualización final en Power BI.

La solución es coherente con el caso de uso porque los datos tienen naturaleza histórica y mensual. No requieren procesamiento en tiempo real, sino consolidación fiable, control de calidad, transformación reproducible y generación de indicadores para reporting operativo.

El principal valor técnico del proyecto está en la trazabilidad. Se conserva el dato RAW, se valida su calidad, se corrige mediante Spark, se publica una capa TRUSTED, se generan salidas ANALYTICS y se consumen los resultados desde Athena y Power BI. Cada KPI del dashboard puede explicarse a partir del flujo de datos que lo genera.

Desde el punto de vista de negocio, el proyecto permite identificar provincias con mayor carga, oficinas con menor rendimiento, meses o unidades con riesgo operativo elevado y posibles prioridades de seguimiento. La solución no se limita a almacenar o mostrar datos, sino que convierte información operativa en criterios de decisión.

Mejoras futuras

Mejora futura	Descripción
Parquet y particionado	Convertir TRUSTED y ANALYTICS a Parquet y particionar por año, mes o provincia para optimizar Athena.
Orquestación	Automatizar ejecuciones con EventBridge, Step Functions o workflows de Glue.

Lake Formation	Aplicar permisos finos por tabla, columna o perfil de usuario.
Observabilidad	Publicar métricas de ejecución y calidad en CloudWatch.
CI/CD de datos	Versionar scripts, rulesets y SQL en un repositorio para mejorar mantenimiento.
Dashboard avanzado	Añadir drill-through por oficina, tooltips enriquecidos y alertas de riesgo operativo.
Analítica predictiva	Incorporar modelos de predicción para anticipar saturación, incidencias o caída de satisfacción.

20.1. Evolución del piloto hacia una solución institucional

Como piloto académico, la solución demuestra la viabilidad de construir una arquitectura Big Data trazable, gobernada y orientada a indicadores. En una evolución hacia un entorno institucional real, el proyecto podría ampliarse con series históricas multianuales, integración con sistemas origen, automatización de cargas, cifrado gestionado, control de permisos granular, monitorización del pipeline y despliegue controlado mediante prácticas de DevOps y DataOps.

Nivel de madurez	Evolución propuesta
Piloto académico	Carga manual controlada, CSV sintético, ejecución en AWS Academy y dashboard Power BI.
Piloto institucional ampliado	Automatización mensual, histórico multianual, validaciones programadas y control de acceso por perfiles.
Entorno productivo	Orquestación, CI/CD, monitorización, alertas, auditoría, cifrado gestionado y gobierno corporativo.
Futuro módulo de IA	Modelos predictivos para anticipar saturación, incidencias, esperas elevadas o caída de satisfacción.

21. Uso responsable de IA generativa

La IA generativa se ha utilizado como apoyo para estructurar la memoria, revisar coherencia técnica, mejorar la redacción, preparar guías de ejecución y reforzar la interpretación de resultados.

Su uso no sustituye la ejecución técnica del proyecto. Las decisiones arquitectónicas, la configuración de servicios, las reglas de calidad, las consultas Athena, el job Spark y el dashboard Power BI se respaldan mediante evidencias reales obtenidas durante el laboratorio.

El criterio seguido ha sido utilizar la IA como herramienta de apoyo documental y revisión, manteniendo la responsabilidad sobre la comprensión, validación y defensa del proyecto. Las capturas, resultados y

explicaciones incluidas en la memoria corresponden al trabajo ejecutado en AWS Academy / Learner Lab y Power BI Desktop.

22. Anexos técnicos

Los anexos técnicos recogen fragmentos representativos de reglas, consultas, medidas y código utilizados durante el proyecto. El objetivo es facilitar la revisión sin sobrecargar el cuerpo principal de la memoria.

22.1. Extracto DQDL RAW

El ruleset RAW se utilizó para diagnosticar problemas iniciales del dataset bruto. Incluye reglas de existencia de columnas, completitud, unicidad, validez numérica, rangos permitidos, categorías controladas y volumetría mínima.

```
Rules = [  
    ColumnExists "registro_id",  
    ColumnExists "mes",  
    ColumnExists "oficina_id",  
    ColumnExists "oficina",  
    ColumnExists "provincia",  
    ColumnExists "expedientes_recibidos",  
    ColumnExists "expedientes_resueltos",  
    ColumnExists "incidencias_abiertas",  
    ColumnExists "tiempo_medio_espera_min",  
    ColumnExists "nivel_servicio",  
    ColumnExists "satisfaccion_media",  
  
    IsComplete "registro_id",  
    IsComplete "mes",  
    IsComplete "oficina_id",  
    IsComplete "oficina",  
    IsComplete "provincia",  
    IsComplete "expedientes_recibidos",  
  
    IsUnique "registro_id",  
  
    ColumnValues "expedientes_recibidos" >= 0,  
    ColumnValues "expedientes_resueltos" >= 0,  
    ColumnValues "documentacion_pendiente" >= 0,
```

```

ColumnValues "incidencias_abiertas" >= 0,

ColumnValues "tiempo_medio_espera_min" >= 0,


ColumnValues "satisfaccion_media" between 1 and 5,

ColumnValues "nivel_servicio" in ["alto", "medio", "bajo"],

ColumnValues "canal_principal" in ["presencial", "online", "telefono"],

RowCount > 90

]

```

22.2. Extracto DQDL TRUSTED

El ruleset TRUSTED se aplicó tras la transformación Spark para comprobar que la capa final cumplía las reglas principales de calidad.

```

Rules = [

    ColumnExists "registro_id",

    ColumnExists "mes",

    ColumnExists "oficina_id",

    ColumnExists "oficina",

    ColumnExists "provincia",

    ColumnExists "comunidad_autonoma",

    ColumnExists "zona_operativa",

    ColumnExists "canal_principal",

    ColumnExists "prioridad_media_expedientes",

    ColumnExists "expedientes_recibidos",

    ColumnExists "expedientes_resueltos",

    ColumnExists "documentacion_pendiente",

    ColumnExists "incidencias_abiertas",

    ColumnExists "tiempo_medio_espera_min",

    ColumnExists "nivel_servicio",

    ColumnExists "satisfaccion_media",

    ColumnExists "tasa_resolucion_pct",

    ColumnExists "ratio_incidencias_pct",

    ColumnExists "riesgo_operativo",


    IsComplete "registro_id",

    IsComplete "mes",

    IsComplete "oficina_id",

    IsComplete "oficina",

```

```

IsComplete "provincia",
IsComplete "expedientes_recibidos",
IsComplete "expedientes_resueltos",

IsUnique "registro_id",

ColumnValues "expedientes_recibidos" >= 0,
ColumnValues "expedientes_resueltos" >= 0,
ColumnValues "documentacion_pendiente" >= 0,
ColumnValues "incidencias_abiertas" >= 0,
ColumnValues "tiempo_medio_espera_min" >= 0,

ColumnValues "satisfaccion_media" between 1 and 5,
ColumnValues "tasa_resolucion_pct" between 0 and 100,
ColumnValues "ratio_incidencias_pct" >= 0,
ColumnValues "nivel_servicio" in ["alto", "medio", "bajo"],
ColumnValues "canal_principal" in ["presencial", "online", "telefono"],
ColumnValues "prioridad_media_expedientes" in ["alta", "media", "baja"],
ColumnValues "riesgo_operativo" in ["alto", "medio", "bajo"],
RowCount = 96
]

```

22.3. SQL representativo de Athena

Las consultas Athena se ejecutaron sobre las tablas reales registradas por Glue Data Catalog. Los nombres usados en laboratorio fueron `trusted_oficinas`, `analytics_kpis_oficina`, `analytics_kpis_provincia` y `analytics_resumen`.

```

USE proyecto_bigdata_oficinas;

-- Resumen ejecutivo anual
SELECT *
FROM analytics_resumen;

-- Ranking anual de carga por oficina
SELECT
    oficina_id,
    oficina,
    provincia,

```

```

SUM(expedientes_recibidos) AS expedientes_recibidos_total,
SUM(expedientes_resueltos) AS expedientes_resueltos_total,
SUM(incidencias_abiertas) AS incidencias_abiertas_total,
ROUND(SUM(expedientes_resueltos) * 100.0 / SUM(expedientes_recibidos), 2) AS tasa_resolucion_pct,
ROUND(SUM(incidencias_abiertas) * 100.0 / SUM(expedientes_recibidos), 2) AS ratio_incidencias_pct,
ROUND(AVG(tiempo_medio_espera_min), 1) AS espera_media_min,
ROUND(AVG(satisfaccion_media), 2) AS satisfaccion_media
FROM trusted_oficinas
GROUP BY oficina_id, oficina, provincia
ORDER BY expedientes_recibidos_total DESC;

-- Oficinas con mayor riesgo operativo
SELECT
oficina_id,
oficina,
provincia,
COUNT_IF(riesgo_operativo = 'alto') AS meses_riesgo_alto,
COUNT_IF(riesgo_operativo = 'medio') AS meses_riesgo_medio,
COUNT_IF(riesgo_operativo = 'bajo') AS meses_riesgo_bajo,
ROUND(AVG(tasa_resolucion_pct), 2) AS tasa_resolucion_media_pct,
ROUND(AVG(ratio_incidencias_pct), 2) AS ratio_incidencias_medio_pct,
ROUND(AVG(tiempo_medio_espera_min), 1) AS espera_media_min,
ROUND(AVG(satisfaccion_media), 2) AS satisfaccion_media
FROM trusted_oficinas
GROUP BY oficina_id, oficina, provincia
ORDER BY meses_riesgo_alto DESC, espera_media_min DESC;

-- KPIs agregados por provincia
SELECT
provincia,
comunidad_autonoma,
SUM(expedientes_recibidos) AS expedientes_recibidos_total,
SUM(expedientes_resueltos) AS expedientes_resueltos_total,
SUM(incidencias_abiertas) AS incidencias_abiertas_total,
SUM(documentacion_pendiente) AS documentacion_pendiente_total,
ROUND(SUM(expedientes_resueltos) * 100.0 / SUM(expedientes_recibidos), 2) AS tasa_resolucion_pct,
ROUND(SUM(incidencias_abiertas) * 100.0 / SUM(expedientes_recibidos), 2) AS ratio_incidencias_pct,

```



```

ROUND(AVG(tiempo_medio_espera_min), 1) AS espera_media_min,
ROUND(AVG(satisfaccion_media), 2) AS satisfaccion_media
FROM analytics_kpis_provincia
GROUP BY provincia, comunidad_autonoma
ORDER BY expedientes_recibidos_total DESC;

-- Validación técnica final de TRUSTED
SELECT 'filas_trusted' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas

UNION ALL

SELECT 'registros_con_nulos_clave' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas
WHERE registro_id IS NULL
    OR mes IS NULL
    OR oficina_id IS NULL
    OR oficina IS NULL
    OR provincia IS NULL
    OR expedientes_recibidos IS NULL

UNION ALL

SELECT 'registros_con_metricas_negativas' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas
WHERE expedientes_recibidos < 0
    OR expedientes_resueltos < 0
    OR documentacion_pendiente < 0
    OR incidencias_abiertas < 0
    OR tiempo_medio_espera_min < 0

UNION ALL

SELECT 'registros_resueltos_mayor_recibidos' AS validacion, COUNT(*) AS resultado
FROM trusted_oficinas
WHERE expedientes_resueltos > expedientes_recibidos;

```

22.4. Medidas DAX representativas

Las medidas DAX se construyeron sobre la tabla principal oficinas_empleo_trusted_2025.

Total Expedientes Recibidos =

SUM(oficinas_empleo_trusted_2025[expedientes_recibidos])

Total Expedientes Resueltos =

SUM(oficinas_empleo_trusted_2025[expedientes_resueltos])

Expedientes Pendientes =

[Total Expedientes Recibidos] - [Total Expedientes Resueltos]

Tasa Resolución % =

DIVIDE(
 [Total Expedientes Resueltos],
 [Total Expedientes Recibidos]
) * 100

Incidencias Abiertas =

SUM(oficinas_empleo_trusted_2025[incidencias_abiertas])

Ratio Incidencias % =

DIVIDE(
 [Incidencias Abiertas],
 [Total Expedientes Recibidos]
) * 100

Espera Media Min =

AVERAGE(oficinas_empleo_trusted_2025[tiempo_medio_espera_min]) / 10

Satisfacción Media =

AVERAGE(oficinas_empleo_trusted_2025[satisfaccion_media]) / 100

Meses Riesgo Alto =

CALCULATE(
 COUNTROWS(oficinas_empleo_trusted_2025),
 oficinas_empleo_trusted_2025[riesgo_operativo] = "alto"
)

```

Meses Riesgo Medio =
CALCULATE(
    COUNTROWS(oficinas_empleo_trusted_2025),
    oficinas_empleo_trusted_2025[riesgo_operativo] = "medio"
)

Meses Riesgo Bajo =
CALCULATE(
    COUNTROWS(oficinas_empleo_trusted_2025),
    oficinas_empleo_trusted_2025[riesgo_operativo] = "bajo"
)

Puntuación Riesgo Operativo =
[Meses Riesgo Alto] * 3
+ [Meses Riesgo Medio] * 2
+ [Meses Riesgo Bajo]

```

Nota técnica: durante la importación en Power BI Desktop se detectó una interpretación regional de decimales en determinados campos numéricos. Para mantener la escala 1-5 de satisfacción y la coherencia con el dashboard final, se aplicó un ajuste de escala en la medida Satisfacción Media. Con esta medida, la vista general del dashboard muestra una satisfacción media global de 3,38.

22.5. Extracto representativo de PySpark

El script completo se conserva en la carpeta 06_spark/ y en la ruta scripts/ del bucket S3. A continuación se incluye únicamente un extracto representativo.

```

args = getResolvedOptions(sys.argv, [
    "RAW_PATH",
    "DIM_OFICINAS_PATH",
    "DIM_CALENDARIO_PATH",
    "TRUSTED_PATH",
    "ANALYTICS_OFICINA_PATH",
    "ANALYTICS_PROVINCIA_PATH",
    "ANALYTICS_RESUMEN_PATH"
])

raw = spark.read.option("header", "true").csv(args["RAW_PATH"])

```

```
dim_oficinas = spark.read.option("header", "true").csv(args["DIM_OFICINAS_PATH"])
dim_calendario = spark.read.option("header", "true").csv(args["DIM_CALEDARIO_PATH"])
```

```
base = (
    raw
    .dropDuplicates(["registro_id"])
    .join(dim_oficinas, "oficina_id", "inner")
    .join(dim_calendario, "mes", "left")
)
```

```
base = base.withColumn(
    "expedientes_resueltos",
    when(col("expedientes_resueltos") < 0, 0).otherwise(col("expedientes_resueltos"))
)
```

```
base = base.withColumn(
    "satisfaccion_media",
    least(lit(5.0), greatest(lit(1.0), col("satisfaccion_media")))
)
```

```
base = base.withColumn(
    "tasa_resolucion_pct",
    round((col("expedientes_resueltos") / col("expedientes_recibidos")) * 100, 2)
)
```

[Nota técnica]: "Se aplica .coalesce(1) de forma estrictamente deliberada en la fase final del entorno de laboratorio para consolidar las salidas analíticas en un único fichero .csv limpio. Esto facilita la posterior validación analítica directa en Power BI y Athena sin lidiar con los múltiples ficheros parciales generados por los nodos trabajadores (workers) de Spark. En un entorno de producción corporativo con volumen masivo, esta línea se elimina para permitir la escritura paralela y escalable."

```
base.write.mode("overwrite").option("header", "true").csv(args["TRUSTED_PATH"])
kpis_oficina.write.mode("overwrite").option("header", "true").csv(args["ANALYTICS_OFICINA_PATH"])
kpis_provincia.write.mode("overwrite").option("header", "true").csv(args["ANALYTICS_PROVINCIA_PATH"])
resumen.write.mode("overwrite").option("header", "true").csv(args["ANALYTICS_RESUMEN_PATH"])
```