
Nombre del módulo: Big Data
Nombre del reto: Reto 2 – AWS Glue ETL Job
Alumno/a: Francisca Selma Catalá
Fecha: 06-04-2026
Centro: UAX FP

Índice general

Parte I. Planteamiento del reto y diseño de la solución

1. Introducción
2. Objetivo del caso de uso
3. Dataset utilizado
 - 3.1. Nombre del fichero
 - 3.2. Descripción del dataset
4. Arquitectura general del proceso
5. Servicios AWS utilizados
6. Estructura del almacenamiento en S3
7. Diseño del job en AWS Glue Studio
8. Transformaciones aplicadas
 - 8.1. Transformación Filter
 - 8.2. Transformación SelectFields
 - 8.3. Transformación RenameFields
 - 8.4. Transformación DropFields
9. Justificación global de las transformaciones
10. Configuración del destino
11. Resultado final obtenido
12. Posible evolución analítica del dataset resultante
13. Consideraciones sobre gobierno y protección del dato
14. Conclusión

Parte II. Memoria de ejecución del ejercicio práctico

15. Memoria de ejecución del ejercicio práctico
 - 15.1. Inicio del laboratorio y acceso a la consola de AWS
 - 15.2. Acceso a Amazon S3 y preparación de la estructura de almacenamiento
 - 15.3. Carga del dataset CSV en la carpeta de entrada
 - 15.4. Catalogación del dataset con AWS Glue
 - 15.5. Creación del job visual en AWS Glue Studio
 - 15.6. Aplicación de la transformación Filter
 - 15.7. Aplicación de la transformación SelectFields
 - 15.8. Aplicación de la transformación RenameFields

- 15.9. Aplicación de la transformación DropFields
- 15.10. Configuración del destino en Amazon S3
- 15.11. Revisión del grafo final antes de la ejecución
- 15.12. Ejecución del job en AWS Glue
- 15.13. Revisión del fichero de salida en Amazon S3
- 15.14. Validación del resultado final
- 16. Identificador de la cuenta AWS del laboratorio

Tabla de figuras

- Figura 1. Dataset de entrada cargado en Amazon S3
- Figura 2. Estructura del bucket en Amazon S3
- Figura 3. Grafo final del job en AWS Glue Studio
- Figura 4. Visualización del resultado transformado
- Figura 5. Inicio del laboratorio de AWS Academy
- Figura 6. Acceso a la consola de AWS
- Figura 7. Creación o revisión del bucket de trabajo en Amazon S3
- Figura 8. Organización de carpetas de entrada y salida en S3
- Figura 9. Carga del fichero CSV en Amazon S3
- Figura 10. Verificación del dataset de entrada en S3
- Figura 11. Acceso al área de crawlers de AWS Glue
- Figura 12. Configuración del crawler para el dataset del reto
- Figura 13. Finalización correcta del crawler
- Figura 14. Tabla creada en AWS Glue Data Catalog
- Figura 15. Acceso a AWS Glue Studio para crear el job ETL
- Figura 16. Configuración del nodo de origen del job
- Figura 17. Configuración de la transformación Filter
- Figura 18. Configuración de la transformación SelectFields
- Figura 19. Configuración de la transformación RenameFields
- Figura 20. Flujo intermedio del job con las transformaciones aplicadas
- Figura 21. Configuración del destino del job en Amazon S3
- Figura 22. Revisión del grafo final del job ejecución
- Figura 23. Lanzamiento y seguimiento de la ejecución del job
- Figura 24. Confirmación de la ejecución correcta del job

Figura 25. Fichero de salida generado por el job ETL

Figura 26. Apertura del fichero transformado para su revisión

Figura 27. Comprobación detallada de la estructura final del dataset

Figura 28. Identificador de la cuenta AWS del laboratorio

1. Introducción

En este reto se ha desarrollado un proceso ETL con AWS Glue a partir de un fichero en formato CSV almacenado en Amazon S3. El trabajo se sitúa dentro de un caso de uso centrado en la gestión de expedientes y la atención al ciudadano en una oficina de empleo.

La finalidad de la práctica no ha sido únicamente aplicar una serie de transformaciones técnicas sobre un conjunto de datos, sino construir una salida más clara, útil y orientada a la gestión. A partir de un dataset administrativo inicial, se ha diseñado un flujo de trabajo en AWS capaz de identificar los expedientes que pueden requerir seguimiento, simplificar la información disponible y dejar preparado un resultado final con valor operativo.

En este sentido, el reto combina dos dimensiones complementarias. Por un lado, una dimensión técnica, relacionada con el uso de Amazon S3 y AWS Glue para cargar, catalogar, transformar y almacenar datos. Por otro, una dimensión funcional, ya que el proceso se orienta a mejorar la organización del servicio, facilitar la detección de incidencias y apoyar el seguimiento de los casos más relevantes dentro de la oficina de empleo.

2. Objetivo del caso de uso

El objetivo principal del proceso ETL consiste en transformar un conjunto de datos administrativos para facilitar la identificación de expedientes que requieren una atención especial o un seguimiento posterior dentro de una oficina de empleo.

De manera más concreta, el trabajo busca:

- detectar expedientes con documentación pendiente,
- identificar casos con incidencias administrativas,
- localizar tiempos de espera elevados en la atención al ciudadano,
- obtener una salida final más reducida, clara y útil para su análisis posterior.

El propósito no es conservar todos los datos del fichero original, sino seleccionar y transformar aquellos que realmente aportan valor para la gestión. De esta manera, el resultado del job se convierte en una tabla operativa de expedientes relevantes, preparada para servir de apoyo en el trabajo diario del servicio.

3. Dataset utilizado

Para el desarrollo del reto se ha utilizado un fichero en formato CSV diseñado para este caso de uso.

3.1 Nombre del fichero

`oficina_empleo_reto2_ampliado.csv`

3.2 Descripción del dataset

El archivo contiene información relacionada con la gestión de expedientes y la atención al ciudadano dentro de una oficina de empleo. En él se recogen datos como el identificador del expediente, la

oficina y provincia, la unidad responsable, el empleado asignado, el tipo de trámite, la prioridad, el estado, la existencia de documentación pendiente, el número de incidencias, el canal de atención, el tiempo de espera o la satisfacción del ciudadano.

Entre las columnas utilizadas en el ejercicio se encuentran, entre otras, las siguientes:

- expediente_id
- oficina
- provincia
- unidad_responsable
- empleado_asignado
- tipo_tramite
- prioridad_expediente
- fecha_entrada
- fecha_resolucion
- estado_expediente
- documentacion_pendiente
- numero_incidentes
- incidencias
- canal_atencion
- tiempo_espera_min
- resultado_cita
- satisfaccion_ciudadano
- mes_expediente
- trimestre
- anio

Se trata de un dataset adecuado para este reto porque combina información administrativa, variables operativas y elementos de seguimiento que permiten construir una salida con sentido funcional. Gracias a ello, el trabajo no se limita a una simple transformación técnica, sino que genera una tabla final con utilidad razonable para supervisión, control y análisis del servicio.




Figura 1. Dataset de entrada cargado en Amazon S3

En esta imagen se muestra el fichero oficina_empleo_reto2_ampliado.csv ya almacenado en la carpeta de entrada del bucket de Amazon S3. A nivel técnico, esta captura permite comprobar que el dataset origen se ha cargado correctamente y que está disponible para su posterior catalogación en AWS Glue. En relación con el caso de uso de la oficina de empleo, este fichero representa la base de datos administrativa a partir de la cual se identificarán expedientes con documentación pendiente, incidencias o tiempos de espera elevados.

4. Arquitectura general del proceso

El procesamiento de los datos se ha realizado en modalidad batch, partiendo de un fichero CSV cargado previamente en Amazon S3. A partir de esa fuente de entrada, se ha seguido un flujo de trabajo sencillo y ordenado:

- almacenamiento del fichero en S3,
- catalogación del dataset en AWS Glue,
- creación del job visual en Glue Studio,
- aplicación de varias transformaciones sobre los datos,
- escritura del resultado final en una ruta de salida dentro de S3,
- comprobación de la ejecución correcta del job.

La arquitectura utilizada se apoya en dos servicios principales: Amazon S3 como sistema de almacenamiento y AWS Glue como herramienta de integración y transformación de datos. Esta combinación permite construir una solución simple, coherente con el laboratorio y suficientemente escalable para una futura ampliación del caso de uso.

5. Servicios AWS utilizados

Para llevar a cabo el reto se han utilizado principalmente Amazon S3 y AWS Glue.

Amazon S3 se ha utilizado como sistema de almacenamiento tanto para el fichero de entrada como para la salida del proceso ETL. Su uso permite organizar la información por rutas, mantener separadas las distintas fases del tratamiento del dato y conservar el dataset original sin modificar.

AWS Glue se ha utilizado para reconocer la estructura del fichero, catalogar el dataset, diseñar el flujo visual de transformación, ejecutar el job ETL y generar el resultado final.

El uso conjunto de ambos servicios proporciona una base limpia, flexible y lógica para este caso práctico, ya que permite trabajar sobre datos administrativos de una manera estructurada y reproducible.

6. Estructura del almacenamiento en S3

La organización del bucket se ha planteado de forma simple, separando claramente los datos de entrada y los datos de salida.

Ejemplo de estructura utilizada:

s3://reto2-oficina-empleo-fs/entrada/oficina_empleo_reto2_ampliado.csv

s3://reto2-oficina-empleo-fs/salida_oficina_empleo_transformado/

Esta organización permite conservar el fichero original sin modificar, almacenar la salida transformada en una ruta independiente, evitar sobrescrituras y facilitar la revisión posterior del proceso.




Figura 2. Estructura del bucket en Amazon S3


En esta captura se observa la organización del almacenamiento en Amazon S3, separando la carpeta de entrada de la carpeta de salida. A nivel técnico, esta estructura permite diferenciar claramente el fichero original del resultado transformado generado por el job ETL. En el contexto del reto de la oficina de empleo, esta separación resulta especialmente útil porque permite conservar el dataset administrativo de partida y, al mismo tiempo, obtener una nueva versión más depurada y orientada al seguimiento de expedientes relevantes.

7. Diseño del job en AWS Glue Studio

En AWS Glue Studio se ha diseñado un flujo visual con una estructura sencilla y fácil de interpretar:

Origen de datos → Transformaciones → Destino en S3

Se ha optado por una solución visual porque facilita tanto la configuración del proceso como su explicación en la memoria. El flujo parte de la tabla catalogada del dataset original, aplica varias transformaciones secuenciales y escribe el resultado final en una carpeta de salida del bucket.



En esta imagen se muestra el grafo final del proceso ETL diseñado en AWS Glue Studio. A nivel técnico, puede observarse la secuencia completa del flujo, desde la lectura del dataset catalogado hasta la escritura del resultado final en Amazon S3. En relación con el reto de la oficina de empleo, este grafo representa la lógica general del trabajo realizado: partir de un conjunto de datos administrativos amplio y transformarlo en una salida más clara y útil para el seguimiento de casos relevantes.

Para cumplir con el reto se han aplicado cuatro transformaciones visuales dentro de AWS Glue Studio. Se trata de transformaciones sencillas, pero con sentido funcional dentro del caso de uso planteado.

La primera transformación ha sido **Filter**, utilizada para conservar únicamente los expedientes con mayor interés operativo. Para ello se han utilizado condiciones relacionadas con documentación pendiente, incidencias administrativas o tiempos de espera elevados.

8.2 SelectFields

La segunda transformación ha sido **SelectFields**, con el objetivo de mantener únicamente las columnas necesarias para la salida final.

Las columnas seleccionadas han sido las siguientes:

- expediente_id
- oficina
- provincia
- unidad_responsable
- empleado_asignado
- tipo_tramite
- prioridad_expediente
- fecha_entrada
- fecha_resolucion
- estado_expediente
- documentacion_pendiente
- numero_incidentes
- incidencias
- canal_atencion
- tiempo_espera_min
- resultado_cita
- satisfaccion_ciudadano
- mes_expediente
- trimestre
- anio

8.3 RenameFields

La tercera transformación ha sido **RenameFields**, utilizada para hacer más comprensibles algunos nombres de columnas.

Los cambios realizados son los siguientes:

- oficina → oficina_empleo
- unidad_responsable → unidad_gestion
- tipo_tramite → tramite
- tiempo_espera_min → espera_minutos
- numero_incidentes → incidentes_total
- satisfaccion_ciudadano → nivel_satisfaccion

Aunque esta transformación no altera el contenido de los datos, sí mejora la legibilidad de la tabla final y facilita su uso para revisión, supervisión o elaboración de informes.

8.4 DropFields

La cuarta transformación ha sido **DropFields**, con la finalidad de eliminar algunos campos que ya no aportaban valor a la salida final.

En este caso, se han eliminado:

- provincia
- fecha_resolucion

Con ello se consigue una tabla más limpia, más enfocada y alineada con la lógica de seguimiento operativo que se persigue en el caso de uso.

9. Justificación global de las transformaciones

Las transformaciones elegidas no responden únicamente a la necesidad de cumplir con el número mínimo exigido en el reto, sino también a una lógica funcional concreta.

Filter permite quedarse con los expedientes que requieren mayor atención. SelectFields reduce el dataset a la información realmente necesaria. RenameFields mejora la comprensión del resultado final. DropFields elimina ruido y refuerza la orientación práctica de la salida.

En conjunto, estas cuatro transformaciones convierten el fichero original en una tabla más útil para la gestión y la supervisión del servicio. El valor del proceso no está solo en transformar datos, sino en dejar preparada una base de información con más sentido operativo dentro del contexto de una oficina de empleo.

10. Configuración del destino

Después de aplicar las transformaciones, la salida del job se almacena en Amazon S3 en formato **CSV**. Se ha optado por este formato por su sencillez, su facilidad de lectura y su compatibilidad con herramientas de revisión rápida.

11. Resultado final obtenido

Como resultado del proceso ETL se obtiene una tabla transformada de expedientes relevantes, almacenada en Amazon S3.

Esta salida final presenta varias mejoras respecto al fichero original:

- contiene únicamente los expedientes de mayor interés para seguimiento,
- reduce el número de columnas,
- presenta nombres de campos más claros,
- y queda preparada para su consulta y análisis posterior.

Más allá de ser un simple archivo transformado, esta salida puede entenderse como un **dataset transformado de seguimiento**, útil para la identificación de incidencias, documentación pendiente o tiempos de espera que puedan requerir intervención organizativa.

expediente_id	empleado_asignado	prioridad	exp_fecha	entrad_estado	expac_documento	incidencias	canal_atencion	resultado	chi_mes	expediente_trimestre	anio	oficina_empla_unidad_gesti	trámite	espera_minut	incidentes	se_nivel_satisfaccion
EXP00001	Luis Gálvez	baja	06/05/2024	pendiente_dc	0	error_datos	no_presencial	atendida	2024-05	T3	2024	Madrid Centro Reclamaciones	reclamacion	16	2	may_alta
EXP00002	Sergio Vidal	media	24/05/2024	pendiente_dc	2	documental	no_presencial	atendida	2024-05	T2	2024	Barcelona Sur Reclamaciones	reclamacion	95	1	media
EXP00003	Sergio Vidal	alta	17/05/2024	pendiente_dc	0	documental	no_presencial	atendida	2024-05	T3	2024	Barcelona Sur Prestaciones	orientacion	8	3	alta
EXP00004	Ana Huachín	media	17/05/2024	resuelto	4	documental	no_presencial	atendida	2024-05	T2	2024	Barcelona Sur Orientación	orientacion	56	0	media
EXP00005	Luis Gálvez	baja	27/03/2024	en_tramitacion	1	incidencia	no_presencial	reprogramada	2024-03	T1	2024	Madrid Centro Demanda	subsidio	41	0	may_alta
EXP00006	Paula Romero	media	22/02/2024	cerrado	1	sin_incidencia	no_presencial	atendida	2024-02	T1	2024	Valencia Norte Reclamaciones	orientacion	73	1	baja
EXP00007	Diego Sánchez	baja	21/07/2024	pendiente_dc	2	documental	no_presencial	reprogramada	2024-07	T3	2024	Madrid Centro Reclamaciones	reclamacion	51	0	alta
EXP00008	Elena Navarro	baja	09/04/2024	resuelto	0	incidencia	no_presencial	atendida	2024-04	T2	2024	Sevilla Este Prestaciones	reclamacion	46	0	may_alta
EXP00009	Paula Romero	baja	18/05/2024	en_tramitacion	0	documental	no_presencial	atendida	2024-05	T3	2024	Madrid Centro Orientación	reclamacion	8	2	media
EXP00010	Carlos Páñez	media	12/03/2024	incidencia	1	incidencia	no_presencial	atendida	2024-03	T1	2024	Valencia Norte Demanda	reclamacion	66	0	alta
EXP00011	Ana Huachín	media	15/05/2024	resuelto	0	documental	no_presencial	atendida	2024-05	T3	2024	Madrid Centro Orientación	reclamacion	68	1	alta
EXP00012	Marta Ruiz	alta	23/04/2024	en_tramitacion	1	incidencia	no_presencial	atendida	2024-04	T2	2024	Madrid Centro Reclamaciones	reclamacion	26	1	alta
EXP00013	Marta Ruiz	baja	27/06/2024	en_tramitacion	2	documental	no_presencial	atendida	2024-06	T2	2024	Madrid Centro Prestaciones	reclamacion	44	0	media
EXP00014	Elena Navarro	baja	04/04/2024	pendiente_dc	3	sin_incidencia	no_presencial	atendida	2024-04	T2	2024	Madrid Centro Subsidios	subsidio	95	1	alta
EXP00015	Carlos Páñez	baja	11/02/2024	incidencia	2	retraso_retraso	no_presencial	reprogramada	2024-02	T1	2024	Barcelona Sur Prestaciones	reclamacion	49	3	alta
EXP00016	Paula Romero	baja	14/07/2024	resuelto	0	documental	no_presencial	atendida	2024-07	T3	2024	Sevilla Este Demanda	orientacion	3	2	baja
EXP00017	Luis Gálvez	alta	20/04/2024	cerrado	0	incidencia	no_presencial	atendida	2024-04	T2	2024	Málaga Cost. Subsidios	orientacion	57	3	alta
EXP00018	Luis Gálvez	media	31/07/2024	pendiente_dc	1	incidencia	no_presencial	atendida	2024-07	T3	2024	Málaga Cost. Subsidios	orientacion	81	0	alta
EXP00019	Carlos Páñez	baja	13/03/2024	cerrado	0	retraso_retraso	no_presencial	atendida	2024-03	T1	2024	Madrid Centro Prestaciones	subsidio	86	1	media
EXP00020	Elena Navarro	baja	24/07/2024	cerrado	0	retraso_retraso	no_presencial	reprogramada	2024-07	T3	2024	Barcelona Sur Reclamaciones	subsidio	70	3	media
EXP00021	Javier Ortega	alta	17/07/2024	incidencia	2	retraso_retraso	no_presencial	atendida	2024-07	T3	2024	Barcelona Sur Reclamaciones	subsidio	86	2	alta
EXP00022	Javier Ortega	media	01/07/2024	pendiente_dc	2	incidencia	no_presencial	reprogramada	2024-07	T3	2024	Barcelona Sur Orientación	reclamacion	57	0	alta
EXP00023	Javier Ortega	baja	26/05/2024	en_tramitacion	1	documental	no_presencial	atendida	2024-05	T2	2024	Sevilla Este Prestaciones	reclamacion	35	0	alta
EXP00024	Sergio Vidal	alta	01/08/2024	en_tramitacion	1	documental	no_presencial	atendida	2024-08	T3	2024	Barcelona Sur Orientación	reclamacion	62	0	media
EXP00025	Marta Ruiz	baja	26/04/2024	en_tramitacion	2	error_datos	no_presencial	atendida	2024-04	T2	2024	Málaga Cost. Orientación	reclamacion	76	1	may_alta
EXP00026	Diego Sánchez	baja	25/07/2024	en_tramitacion	2	documental	no_presencial	atendida	2024-07	T3	2024	Málaga Cost. Orientación	orientacion	23	1	alta
EXP00027	Elena Navarro	alta	24/07/2024	resuelto	1	retraso_retraso	no_presencial	atendida	2024-07	T3	2024	Málaga Cost. Prestaciones	orientacion	85	0	may_alta
EXP00028	Luis Gálvez	media	18/02/2024	cerrado	2	error_datos	no_presencial	atendida	2024-02	T1	2024	Málaga Cost. Reclamaciones	orientacion	53	0	alta
EXP00029	Luis Gálvez	baja	03/01/2024	pendiente_dc	2	retraso_retraso	no_presencial	atendida	2024-01	T1	2024	Málaga Cost. Orientación	reclamacion	21	0	alta
EXP00030	Javier Ortega	baja	03/01/2024	en_tramitacion	2	error_datos	no_presencial	atendida	2024-01	T1	2024	Barcelona Sur Reclamaciones	subsidio	97	0	may_alta
EXP00031	Sergio Vidal	media	03/07/2024	resuelto	2	incidencia	no_presencial	atendida	2024-07	T3	2024	Madrid Centro Subsidios	orientacion	25	0	alta
EXP00032	Javier Ortega	baja	03/04/2024	pendiente_dc	2	documental	no_presencial	atendida	2024-04	T2	2024	Barcelona Sur Reclamaciones	reclamacion	82	2	alta
EXP00033	Paula Romero	media	15/05/2024	pendiente_dc	0	error_datos	no_presencial	atendida	2024-05	T2	2024	Madrid Centro Prestaciones	orientacion	44	0	media
EXP00034	Sergio Vidal	media	17/07/2024	pendiente_dc	3	documental	no_presencial	atendida	2024-07	T3	2024	Madrid Centro Demanda	reclamacion	64	1	may_alta
EXP00035	Sergio Vidal	media	02/04/2024	en_tramitacion	2	documental	no_presencial	atendida	2024-04	T2	2024	Sevilla Este Subsidios	orientacion	51	0	baja
EXP00036	Carlos Páñez	media	17/05/2024	resuelto	0	sin_incidencia	no_presencial	atendida	2024-05	T2	2024	Valencia Norte Subsidios	reclamacion	102	1	media
EXP00037	Luis Gálvez	media	23/04/2024	en_tramitacion	0	error_datos	no_presencial	atendida	2024-04	T2	2024	Madrid Centro Orientación	reclamacion	33	1	alta
EXP00038	Paula Romero	media	15/07/2024	resuelto	3	documental	no_presencial	atendida	2024-07	T3	2024	Barcelona Sur Demanda	orientacion	13	1	media

Figura 4. Visualización del resultado transformado

En esta captura se observa el fichero de salida generado por AWS Glue una vez abierto para su revisión. A nivel técnico, la imagen permite comprobar que el job ETL ha producido correctamente un dataset transformado de expedientes relevantes. En el marco del reto de la oficina de empleo, esta salida final representa una versión más operativa del dataset original, centrada en expedientes relevantes para seguimiento y análisis posterior.

12. Posible evolución analítica del dataset resultante

Aunque en este reto el objetivo se centra en la transformación batch de los datos, el dataset resultante deja preparada una base útil para futuras ampliaciones analíticas.

En una evolución posterior, la salida podría emplearse para construir análisis orientados a estimar retrasos, detectar saturación en determinadas unidades o anticipar picos de demanda en la atención al ciudadano.

Variables como documentacion_pendiente, incidentes_total, espera_minutos, prioridad_expediente, unidad_gestion o mes_expediente podrían servir más adelante como base para análisis predictivos sencillos relacionados con demora, carga operativa o comportamiento del servicio.

Esta posibilidad refuerza el valor del trabajo realizado, ya que muestra que una buena organización y preparación del dato puede servir como base para mejoras posteriores tanto técnicas como funcionales.

13. Consideraciones sobre gobierno y protección del dato

Aunque el dataset utilizado en este trabajo ha sido creado con fines académicos, el caso de uso representa información administrativa relacionada con expedientes y atención al ciudadano. Por ello, en un entorno real sería necesario aplicar medidas claras de protección y gobierno del dato.

Entre estas medidas cabría incluir la anonimización o seudonimización de identificadores, el control de accesos, la limitación del uso de la información a perfiles autorizados y la minimización de datos en las salidas operativas.

En este sentido, el propio diseño del ETL ya incorpora una lógica básica de gobernanza, al seleccionar solo la información necesaria y eliminar campos que no resultan imprescindibles para el objetivo del seguimiento.

En un contexto de administración pública, este aspecto resulta especialmente relevante, ya que el uso del dato debe contribuir a mejorar la gestión del servicio sin comprometer la privacidad ni los derechos de las personas atendidas.

14. Conclusión

En este reto se ha desarrollado un proceso ETL batch con AWS Glue a partir de un fichero CSV almacenado en Amazon S3.

El trabajo ha consistido en transformar un conjunto de datos administrativos relacionados con una oficina de empleo en una salida más depurada, manejable y útil para su revisión posterior. Para ello, se ha construido un flujo sencillo en AWS Glue Studio, aplicando cuatro transformaciones visuales con una lógica bastante clara: filtrar los registros más relevantes, seleccionar solo la información necesaria, renombrar algunos campos para que el resultado sea más comprensible y eliminar columnas que ya no aportaban valor a la salida final.

Aunque a nivel técnico se trata de un ejercicio de ETL, lo más interesante del trabajo ha sido entender que detrás de cada transformación hay una decisión que busca dar más sentido a la información. El resultado no es solo un archivo transformado, sino una tabla más enfocada al seguimiento de expedientes que pueden requerir atención, revisión o control dentro del funcionamiento de una oficina de empleo.

Además, una solución de este tipo podría aportar valor real en un entorno de trabajo, ya que permite ordenar mejor la información, reducir ruido y centrar la atención en los casos que realmente importan. También deja preparada una base que podría reutilizarse más adelante para informes, cuadros de mando o análisis más avanzados, lo que demuestra que incluso una solución sencilla puede tener recorrido si está bien planteada desde el principio.

Como posible evolución, la solución podría automatizarse, mejorar la organización de la salida en S3 y conectarse con herramientas de análisis, visualización o alertas. Esto permitiría dar continuidad al proceso y acercarlo más a un uso real y operativo.

A nivel personal, este reto me ha ayudado a ver con más claridad que trabajar con datos no consiste solo en aplicar herramientas, sino en entender qué problema se quiere resolver y cómo traducirlo en una solución útil. Creo que esa es la parte más importante del ejercicio: comprobar que una buena organización del dato puede servir para mejorar procesos, facilitar el trabajo diario y apoyar decisiones de una forma más ordenada y práctica.

15. Memoria de ejecución del ejercicio práctico

A continuación, se presenta la memoria de ejecución del reto siguiendo el **orden real de trabajo** realizado en el laboratorio. Esta parte no pretende volver a explicar la teoría del caso de uso, sino mostrar de manera cronológica cómo se ha construido el proceso ETL, desde el arranque del entorno hasta la comprobación del resultado final.

15.1 Inicio del laboratorio y acceso a la consola de AWS

El ejercicio comienza con la activación del laboratorio de AWS Academy y el acceso a la consola de AWS. Este paso constituye el punto de partida del trabajo práctico, ya que es el momento en el que queda disponible el entorno cloud necesario para utilizar Amazon S3 y AWS Glue.




Figura 5. Inicio del laboratorio de AWS Academy

En esta imagen se muestra el inicio del entorno de laboratorio desde el que se va a desarrollar toda la práctica. A nivel técnico, este paso permite activar el entorno temporal de AWS necesario para trabajar con los servicios cloud del ejercicio. Aunque todavía no se ha iniciado el proceso ETL, esta acción es imprescindible porque constituye el punto de partida real del reto.




Figura 6. Acceso a la consola de AWS

En esta captura se observa la entrada en la consola principal de AWS. A nivel técnico, esta pantalla confirma que la cuenta de laboratorio está operativa y que ya se puede comenzar a trabajar con servicios como Amazon S3 y AWS Glue. Dentro del reto de la oficina de empleo, este paso marca el inicio efectivo de la construcción de la solución ETL.

15.2 Acceso a Amazon S3 y preparación de la estructura de almacenamiento

Una vez dentro de AWS, se accede a Amazon S3 para preparar la base de almacenamiento del ejercicio. En esta fase se organiza el bucket que alojará tanto el fichero de entrada como la salida final del proceso.




Figura 7. Creación o revisión del bucket de trabajo en Amazon S3.

En esta imagen se muestra el bucket que se utilizará durante la práctica. A nivel técnico, este bucket constituye el espacio de almacenamiento donde se guardará el dataset de entrada y también la salida generada por AWS Glue. En el contexto del reto de la oficina de empleo, este paso es importante porque establece la base sobre la que se organizará todo el flujo de tratamiento del dato.




Figura 8. Organización de carpetas de entrada y salida en S3

En esta captura se aprecia la estructura del bucket organizada en carpetas de entrada y salida. A nivel técnico, esta separación permite diferenciar el fichero original del dataset transformado y evita mezclar ambas fases del proceso. En relación con el reto de la oficina de empleo, esta organización tiene sentido porque permite conservar la información administrativa original y generar una nueva salida más orientada al seguimiento operativo.

15.3 Carga del dataset CSV en la carpeta de entrada

Con la estructura del bucket preparada, el siguiente paso consiste en cargar el fichero CSV del ejercicio en la carpeta de entrada.




Figura 9. Carga del fichero CSV en Amazon S3

En esta imagen se muestra el proceso de carga del fichero `oficina_empleo_reto2_ampliado.csv` en la carpeta de entrada del bucket. A nivel técnico, este paso convierte el archivo CSV en la fuente de datos del proceso ETL. En el marco del reto de la oficina de empleo, este fichero representa el conjunto de datos administrativos sobre el que se trabajará para identificar expedientes relevantes.




Figura 10. Verificación del dataset de entrada en S3

En esta captura se comprueba que el fichero CSV ya se encuentra correctamente almacenado en Amazon S3. A nivel técnico, esta validación confirma que la fuente de datos está disponible para ser catalogada y utilizada por AWS Glue. En relación con el caso de uso, aquí queda fijado el dataset original a partir del cual se construirá la salida final del reto.

15.4 Catalogación del dataset con AWS Glue

Después de cargar el fichero, se accede a AWS Glue para reconocer la estructura del dataset y registrarlo en el catálogo de datos.




Figura 11. Acceso al área de crawlers de AWS Glue

En esta imagen se observa el área de crawlers dentro de AWS Glue. A nivel técnico, este recurso permite analizar el fichero almacenado en S3, detectar su esquema y convertirlo en una tabla utilizable dentro del entorno de Glue. Este paso es importante en el reto porque transforma un archivo CSV en una fuente estructurada preparada para el flujo ETL.




Figura 12. Configuración del crawler para el dataset del reto

En esta captura se muestra el crawler ya configurado para trabajar con el fichero del caso de uso. A nivel técnico, su función es recorrer la ruta de entrada del bucket, identificar las columnas del CSV y generar la tabla correspondiente en Glue Data Catalog. En el reto de la oficina de empleo, este paso es necesario para poder tratar el dataset administrativo como una tabla estructurada sobre la que aplicar transformaciones.




Figura 13. Finalización correcta del crawler

En esta imagen se confirma que el crawler ha terminado correctamente. A nivel técnico, esto significa que AWS Glue ha podido analizar el fichero de entrada sin errores y ha generado su estructura en el catálogo. Esta validación es importante porque asegura que el dataset está preparado para ser utilizado posteriormente en AWS Glue Studio.




Figura 14. Tabla creada en AWS Glue Data Catalog

En esta captura se muestra la tabla generada a partir del fichero CSV. A nivel técnico, esta tabla representa la versión catalogada del dataset y será el origen del job ETL visual. En relación con el reto de la oficina de empleo, este paso permite disponer de una fuente estructurada que contiene campos clave como incidencias, documentación pendiente o tiempos de espera, fundamentales para el análisis posterior.

15.5 Creación del job visual en AWS Glue Studio

Una vez que el dataset ha sido catalogado, se accede a AWS Glue Studio para crear el job ETL visual.




Figura 15. Acceso a AWS Glue Studio para crear el job ETL

En esta imagen se muestra la entrada en AWS Glue Studio. A nivel técnico, este entorno permite diseñar el flujo ETL de forma visual, conectando el origen de datos, las transformaciones y el destino final. En el contexto del reto de la oficina de empleo, aquí comienza la construcción del proceso que convertirá el dataset original en una salida más útil para seguimiento.




Figura 16. Configuración del nodo de origen del job

En esta captura se configura el nodo de origen del flujo ETL seleccionando la tabla catalogada previamente. A nivel técnico, este paso conecta el job con la fuente de datos estructurada creada por el crawler. Dentro del reto, esta acción incorpora formalmente al pipeline la información administrativa de expedientes sobre la que se aplicarán las transformaciones posteriores.

15.6 Aplicación de la transformación Filter

La primera transformación aplicada sobre el dataset es un filtro orientado a conservar solo los expedientes con mayor interés operativo.




Figura 17. Configuración de la transformación Filter

En esta imagen se muestra la configuración de la transformación Filter dentro de AWS Glue Studio. A nivel técnico, este nodo permite conservar únicamente los registros que cumplen determinadas condiciones establecidas sobre el dataset: documentación pendiente, con incidencias o con tiempo de espera superior a un valor determinado. En relación con el reto de la oficina de empleo, esta transformación resulta especialmente importante porque centra la salida en los expedientes que pueden requerir seguimiento, como aquellos con documentación pendiente, incidencias administrativas o tiempos de espera elevados.

15.7 Aplicación de la transformación SelectFields

Después del filtrado, se seleccionan únicamente las columnas necesarias para la salida final.




Figura 18. Configuración de la transformación SelectFields

En esta captura se observa la transformación *SelectFields* ya incorporada al flujo ETL. A nivel técnico, este nodo permite escoger únicamente las columnas que se conservarán en la salida final, reduciendo así el volumen de información del dataset original. En el contexto del reto de la oficina de empleo, esta decisión ayuda a construir una tabla más clara y centrada en los campos realmente útiles para seguimiento y supervisión.

15.8 Aplicación de la transformación *RenameFields*

El siguiente paso del flujo consiste en renombrar algunos campos para hacer la salida más clara y comprensible.




Figura 19. Configuración de las transformaciones *RenameFields*

En esta imagen se muestra la configuración de las transformaciones *RenameFields*. A nivel técnico, este nodo permite cambiar el nombre de varias columnas sin alterar el contenido de los datos. En relación con el reto de la oficina de empleo, esta mejora tiene sentido porque facilita la lectura del resultado final y hace que la tabla transformada resulte más comprensible para tareas de control, seguimiento o revisión operativa.

15.9 Aplicación de la transformación *DropFields*

La última transformación aplicada consiste en eliminar algunos campos que ya no resultan necesarios para la salida final.




Figura 20. Flujo intermedio del job con las transformaciones aplicadas

En esta captura se aprecia el flujo ETL en una fase avanzada, después de aplicar varias transformaciones sobre el dataset original. A nivel técnico, esta parte del proceso refleja la lógica de simplificación de la salida, eliminando campos que dejan de ser necesarios y concentrando la información en un formato más útil. En el contexto del reto de la oficina de empleo, este paso refuerza la idea de que la salida final no pretende ser una copia del archivo inicial, sino una tabla operativa más concreta y enfocada al seguimiento de casos relevantes.

15.10 Configuración del destino en Amazon S3

Una vez finalizadas las transformaciones, se configura el nodo de salida del flujo para guardar el resultado en la carpeta correspondiente del bucket.




Figura 21. Configuración del destino del job en Amazon S3

En esta imagen se muestra la configuración del nodo de salida del proceso ETL. A nivel técnico, este paso permite definir la ruta de Amazon S3 en la que se almacenará el dataset transformado generado por AWS Glue. En relación con el reto de la oficina de empleo, este destino representa la ubicación donde quedará guardada la nueva tabla operativa de expedientes relevantes, ya preparada para su revisión posterior.

15.11 Revisión del grafo final antes de la ejecución

Antes de lanzar el job, se revisa visualmente el flujo completo para comprobar que todas las conexiones y transformaciones están correctamente definidas.





Figura 22. Revisión del grafo final del job ejecución

En esta captura se muestra el grafo completo del job ETL en AWS Glue Studio. A nivel técnico, esta vista resume la secuencia completa del proceso: lectura del origen, aplicación de transformaciones y escritura del resultado en S3. En el contexto del reto de la oficina de empleo, esta imagen sintetiza la lógica global del trabajo realizado y permite visualizar cómo el dataset administrativo original se transforma en una salida orientada a seguimiento operativo.

15.12 Ejecución del job en AWS Glue

Con el flujo ya configurado, se ejecuta el job para que AWS Glue procese el dataset y genere el resultado final.






Figura 23. Lanzamiento y seguimiento de la ejecución del job

En esta imagen se muestra la fase de ejecución del job en AWS Glue. A nivel técnico, este paso pone en marcha el flujo ETL completo, permitiendo que el sistema lea el dataset de entrada, aplique las transformaciones definidas y escriba el resultado en la carpeta de salida de Amazon S3. En relación con el reto de la oficina de empleo, este momento es clave porque demuestra que la solución diseñada funciona realmente y no se limita a una configuración teórica.




Figura 24. Confirmación de la ejecución correcta del job

En esta captura se comprueba que el job ha finalizado correctamente. A nivel técnico, esta evidencia confirma que AWS Glue ha ejecutado el proceso ETL sin errores y ha podido generar el dataset transformado. Esta validación es especialmente importante porque demuestra que la solución diseñada no solo está bien configurada, sino que también funciona correctamente en ejecución.

15.13 Revisión del fichero de salida en Amazon S3

Una vez completada la ejecución, se vuelve al bucket para comprobar que el archivo transformado ha sido generado correctamente.




Figura 25. Fichero de salida generado por el job ETL

En esta imagen se muestran los detalles del archivo de salida generado por AWS Glue en la carpeta correspondiente de Amazon S3. A nivel técnico, esta comprobación permite verificar que el proceso ETL ha producido un fichero real y que el resultado ha quedado almacenado correctamente. En el marco del reto de la oficina de empleo, este archivo representa la tabla transformada de expedientes relevantes obtenida a partir del dataset original.

15.14 Validación del resultado final

El último paso consiste en abrir y revisar el contenido del fichero transformado para comprobar que el resultado coincide con lo esperado, la estructura del dataset coincide con las transformaciones definidas y el archivo de salida es legible y coherente. Abrimos el documento csv con excel en este caso.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V
1	expediente_id	emplead	asig	prioridad	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida	exp_fecha_entrada	exp_fecha_salida
2	EXP00001	Luis Gálvez	baja	06/08/2024	pendiente	0	error_datos_personal	atendida	2024-08	T3	2024	Madrid Centro	Reclamaciones	reclamacion	16	2	may	alta				
3	EXP00002	Sergio Vidal	alta	24/05/2024	pendiente	2	documentacion_incompleta	atendida	2024-05	T2	2024	Barcelona Santa	Reclamaciones	reclamacion	95	1	media					
4	EXP00003	Lucía Torres	media	17/08/2024	pendiente	0	documentacion_incompleta	atendida	2024-08	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	8	3	alta					
5	EXP00004	Ana María	media	17/05/2024	pendiente	4	documentacion_incompleta	atendida	2024-05	T2	2024	Barcelona Santa	Reclamaciones	reclamacion	56	0	media					
6	EXP00005	Lucía Torres	baja	27/03/2024	pendiente	1	sin incidencias	atendida	2024-03	T1	2024	Madrid Centro	Reclamaciones	reclamacion	41	0	may	alta				
7	EXP00006	Paula Romero	media	22/02/2024	pendiente	1	sin incidencias	atendida	2024-02	T1	2024	Valencia Norte	Reclamaciones	reclamacion	73	1	baja					
8	EXP00007	Diego Sánchez	baja	21/07/2024	pendiente	2	documentacion_incompleta	reprogramada	2024-07	T3	2024	Madrid Centro	Reclamaciones	reclamacion	51	0	alta					
9	EXP00008	Elena Navarro	baja	09/04/2024	pendiente	0	incidencia sistema	atendida	2024-04	T2	2024	Sevilla Este	Reclamaciones	reclamacion	46	0	may	alta				
10	EXP00009	Paula Romero	baja	18/08/2024	pendiente	0	documentacion_incompleta	atendida	2024-08	T3	2024	Madrid Centro	Reclamaciones	reclamacion	8	2	media					
11	EXP00010	Carlos Páñez	media	12/03/2024	pendiente	1	incidencia sistema	atendida	2024-03	T1	2024	Valencia Norte	Reclamaciones	reclamacion	66	0	alta					
12	EXP00011	Ana María	media	15/06/2024	pendiente	0	documentacion_incompleta	no presentada	2024-06	T3	2024	Madrid Centro	Reclamaciones	reclamacion	68	1	alta					
13	EXP00012	Marta Ruiz	alta	23/04/2024	pendiente	1	incidencia sistema	atendida	2024-04	T2	2024	Madrid Centro	Reclamaciones	reclamacion	26	1	alta					
14	EXP00013	Marta Ruiz	baja	27/06/2024	pendiente	2	documentacion_incompleta	atendida	2024-06	T2	2024	Madrid Centro	Reclamaciones	reclamacion	44	0	media					
15	EXP00014	Elena Navarro	baja	04/04/2024	pendiente	3	sin incidencias	atendida	2024-04	T2	2024	Madrid Centro	Reclamaciones	reclamacion	95	1	alta					
16	EXP00015	Paula Romero	baja	11/02/2024	pendiente	2	retraso revisión	atendida	2024-02	T1	2024	Barcelona Santa	Reclamaciones	reclamacion	49	3	alta					
17	EXP00016	Diego Sánchez	baja	14/07/2024	pendiente	0	documentacion_incompleta	atendida	2024-07	T3	2024	Sevilla Este	Reclamaciones	reclamacion	3	2	baja					
18	EXP00017	Lucía Torres	alta	10/04/2024	pendiente	0	incidencia sistema	atendida	2024-04	T2	2024	Málaga Costa	Reclamaciones	reclamacion	57	3	alta					
19	EXP00018	Luis Gálvez	media	21/07/2024	pendiente	1	incidencia sistema	atendida	2024-07	T3	2024	Madrid Centro	Reclamaciones	reclamacion	81	0	alta					
20	EXP00019	Carlos Páñez	baja	13/03/2024	pendiente	1	retraso revisión	atendida	2024-03	T1	2024	Madrid Centro	Reclamaciones	reclamacion	86	1	media					
21	EXP00020	Elena Navarro	alta	24/07/2024	pendiente	0	retraso revisión	reprogramada	2024-07	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	70	3	media					
22	EXP00021	Javier Ortega	baja	17/07/2024	pendiente	2	retraso revisión	atendida	2024-07	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	88	2	alta					
23	EXP00022	Javier Ortega	baja	01/07/2024	pendiente	2	incidencia sistema	atendida	2024-07	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	57	0	alta					
24	EXP00023	Javier Ortega	media	29/06/2024	pendiente	1	documentacion_incompleta	atendida	2024-06	T2	2024	Sevilla Este	Reclamaciones	reclamacion	35	0	alta					
25	EXP00024	Sergio Vidal	baja	01/06/2024	pendiente	2	documentacion_incompleta	atendida	2024-06	T2	2024	Barcelona Santa	Reclamaciones	reclamacion	92	0	media					
26	EXP00025	Marta Ruiz	baja	28/04/2024	pendiente	2	error_datos_personal	atendida	2024-04	T2	2024	Madrid Centro	Reclamaciones	reclamacion	75	1	may	alta				
27	EXP00026	Diego Sánchez	baja	25/07/2024	pendiente	2	documentacion_incompleta	atendida	2024-07	T3	2024	Málaga Costa	Reclamaciones	reclamacion	23	1	alta					
28	EXP00027	Elena Navarro	media	24/07/2024	pendiente	1	retraso revisión	atendida	2024-07	T3	2024	Málaga Costa	Reclamaciones	reclamacion	80	0	may	alta				
29	EXP00028	Lucía Torres	media	19/02/2024	pendiente	2	error_datos_personal	atendida	2024-02	T1	2024	Málaga Costa	Reclamaciones	reclamacion	83	0	alta					
30	EXP00029	Carlos Páñez	baja	03/01/2024	pendiente	2	retraso revisión	atendida	2024-01	T1	2024	Málaga Costa	Reclamaciones	reclamacion	21	0	alta					
31	EXP00030	Javier Ortega	baja	03/01/2024	pendiente	2	error_datos_personal	atendida	2024-01	T1	2024	Barcelona Santa	Reclamaciones	reclamacion	97	0	may	alta				
32	EXP00031	Sergio Vidal	media	01/07/2024	pendiente	2	documentacion_incompleta	atendida	2024-07	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	62	2	alta					
33	EXP00032	Javier Ortega	baja	09/04/2024	pendiente	2	documentacion_incompleta	no presentada	2024-04	T2	2024	Barcelona Santa	Reclamaciones	reclamacion	92	0	may	alta				
34	EXP00033	Paula Romero	media	15/06/2024	pendiente	0	error_datos_personal	atendida	2024-06	T2	2024	Madrid Centro	Reclamaciones	reclamacion	44	0	may	alta				
35	EXP00034	Sergio Vidal	media	17/07/2024	pendiente	3	documentacion_incompleta	atendida	2024-07	T3	2024	Madrid Centro	Reclamaciones	reclamacion	64	1	media					
36	EXP00035	Sergio Vidal	media	02/04/2024	pendiente	2	documentacion_incompleta	atendida	2024-04	T2	2024	Sevilla Este	Reclamaciones	reclamacion	51	0	baja					
37	EXP00036	Carlos Páñez	media	17/05/2024	pendiente	6	sin incidencias	atendida	2024-05	T2	2024	Valencia Norte	Reclamaciones	reclamacion	102	1	media					
38	EXP00037	Luis Gálvez	media	20/04/2024	pendiente	0	error_datos_personal	atendida	2024-04	T2	2024	Madrid Centro	Reclamaciones	reclamacion	33	1	alta					
39	EXP00038	Paula Romero	media	15/07/2024	pendiente	3	documentacion_incompleta	atendida	2024-07	T3	2024	Barcelona Santa	Reclamaciones	reclamacion	13	1	media					

Figura 26. Apertura del fichero transformado para su revisión

En esta captura se muestra el archivo de salida ya abierto para comprobar su contenido. A nivel técnico, esta validación permite revisar si el resultado refleja correctamente las transformaciones aplicadas durante el proceso ETL. En relación con el reto de la oficina de empleo, esta imagen confirma que la salida final se ha convertido en una tabla más clara y útil para el seguimiento de expedientes con interés operativo.

</

Figura 27. Comprobación detallada de la estructura final del dataset

En esta imagen se revisan varias columnas y registros del fichero transformado. A nivel técnico, esta comprobación permite validar que la salida final es coherente, legible y consistente con la configuración del job. Dentro del caso de uso de la oficina de empleo, esta revisión final refuerza la idea de que el proceso ETL ha generado un resultado realmente utilizable para supervisión, análisis y seguimiento.

16. Identificador de la cuenta AWS del laboratorio

Para cumplir completamente con el requisito de la entrega, se incluirá también una evidencia visible del identificador de la cuenta AWS del laboratorio.




Figura 28. Identificador de la cuenta AWS del laboratorio

En esta imagen se muestra el ID de cuenta del entorno de laboratorio utilizado para realizar la práctica. Esta evidencia se incorpora porque forma parte de los requisitos formales de la entrega del reto.